Análisis exploratorio de Datos
PCC - UNAM

Sesión I. Introducción.

29-31.01.24

Antonio Neme Castillo

IIMAS UNAM

'The era in which the fermentation of cancer cells or its importance could be disputed is over, and no-one today can doubt that we understand the origin of cancer cells ... if we know how the damaged respiration and the excessive fermentation of cancer cells originate.'

Otto Warburg (1883, 1970)

Mapa de Catalhüyuk (hace 10,000 años)

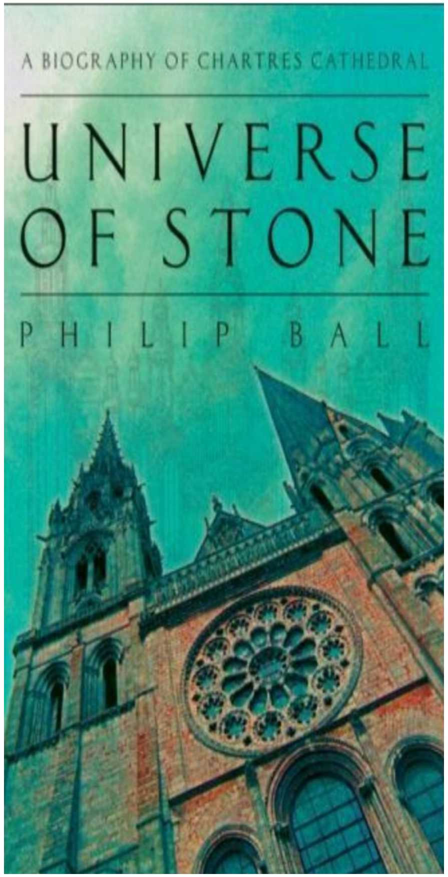

"If we turned our backs on the amazing rational beauty of the universe we live in, we should indeed deserve to be driven therefrom, like a guest unappreciative of the house into which he has been received"

Adelardo de Bath (1080 - 1152)

(Holbein, 1553. *Los Embajadores*)

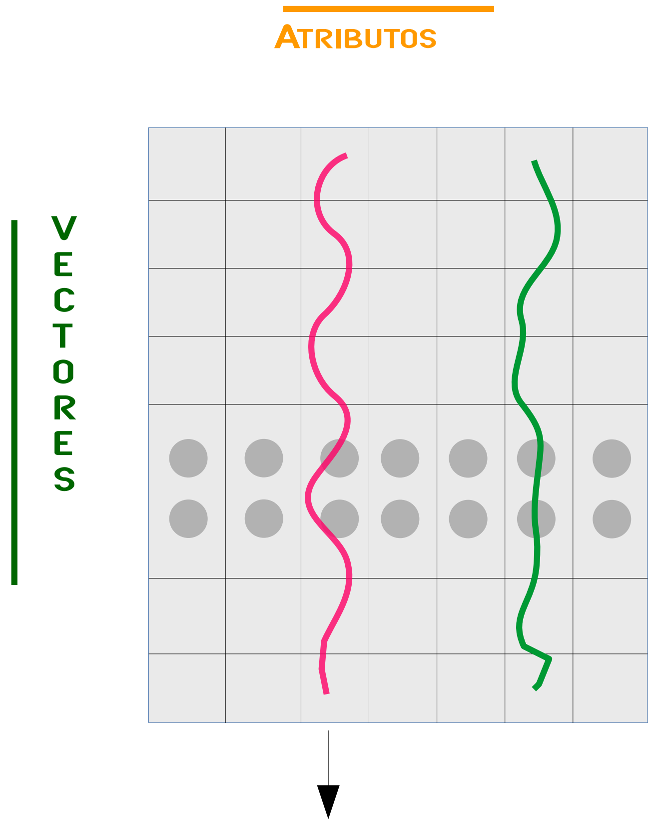

¿Cuál es el comportamiento de este atributo?
Rango, soporte, mínimo, máximo, valor esperado,
Dispersión.

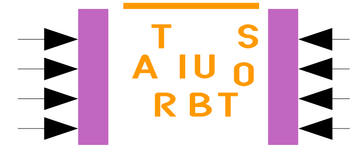

Z = f(Atributos) → DimRed

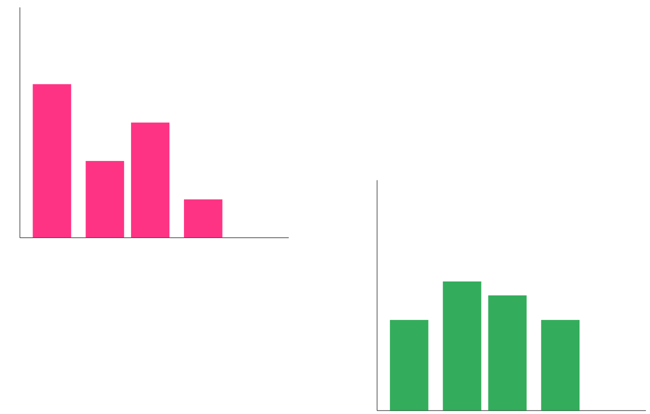

Z = f(Vectores) → VQ

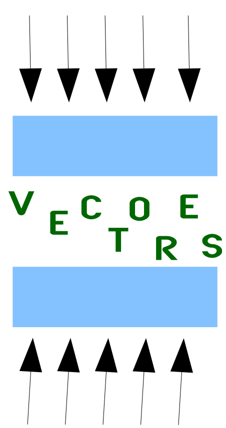

Del rigor en la ciencia

"En aquel Imperio, el Arte de la Cartografía logró tal Perfección que el Mapa de una sola Provincia ocupaba toda una Ciudad, y el Mapa del Imperio, toda una Provincia. Con el tiempo, estos Mapas Desmesurados no satisficieron y los Colegios de Cartógrafos levantaron un Mapa del Imperio, que tenía el Tamaño del Imperio y coincidía puntualmente con él. Menos Adictas al Estudio de la Cartografía, las Generaciones Siguientes entendieron que ese dilatado Mapa era Inútil y no sin Impiedad lo entregaron a las Inclemencias del Sol y los Inviernos. En los Desiertos del Oeste perduran despedazadas Ruinas del Mapa, habitadas por Animales y por Mendigos; en todo el País no hay otra reliquia de las Disciplinas Geográficas."

Suárez Miranda: Viajes de varones prudentes
Libro Cuarto, cap. XLV, Lérida, 1658

De: El hacedor (1960). Jorge Luis Borges

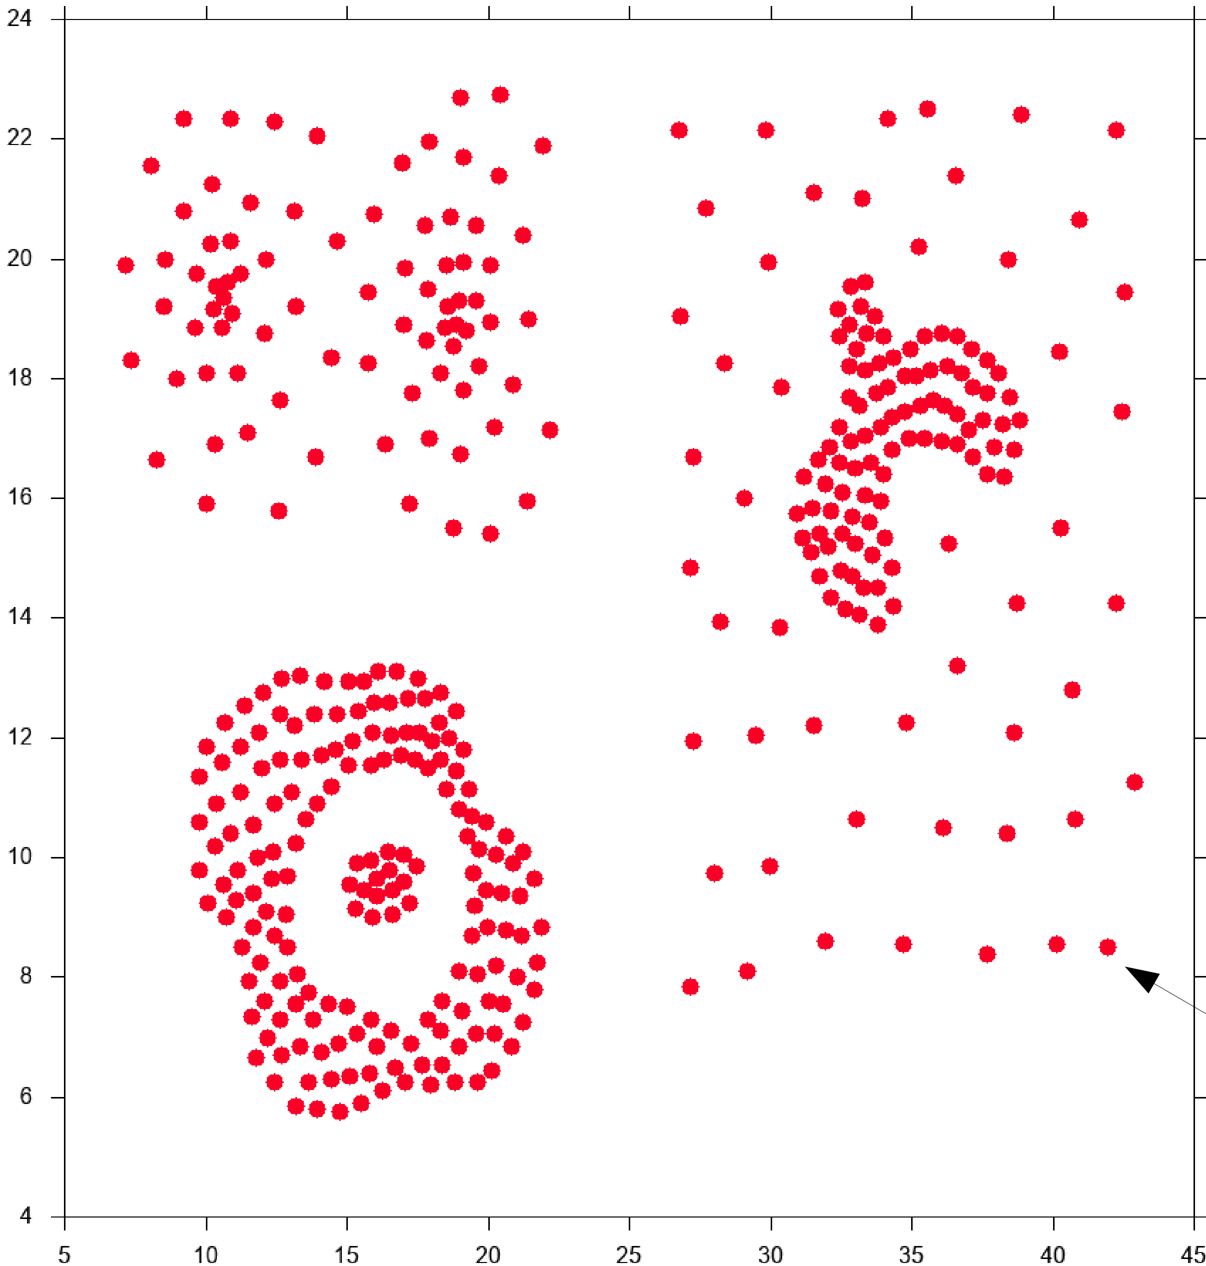

¿HAY ESTRUCTURA EN LOS DATOS?

¿ENCUENTRAN ALGO INTERESANTE?

PUNTO, VECTOR, DATO, OBJETO

DIMENSIÓN, ATRIBUTO, RASGO, CARACTERÍSTICA, OBSERVABLE, VARIABLE

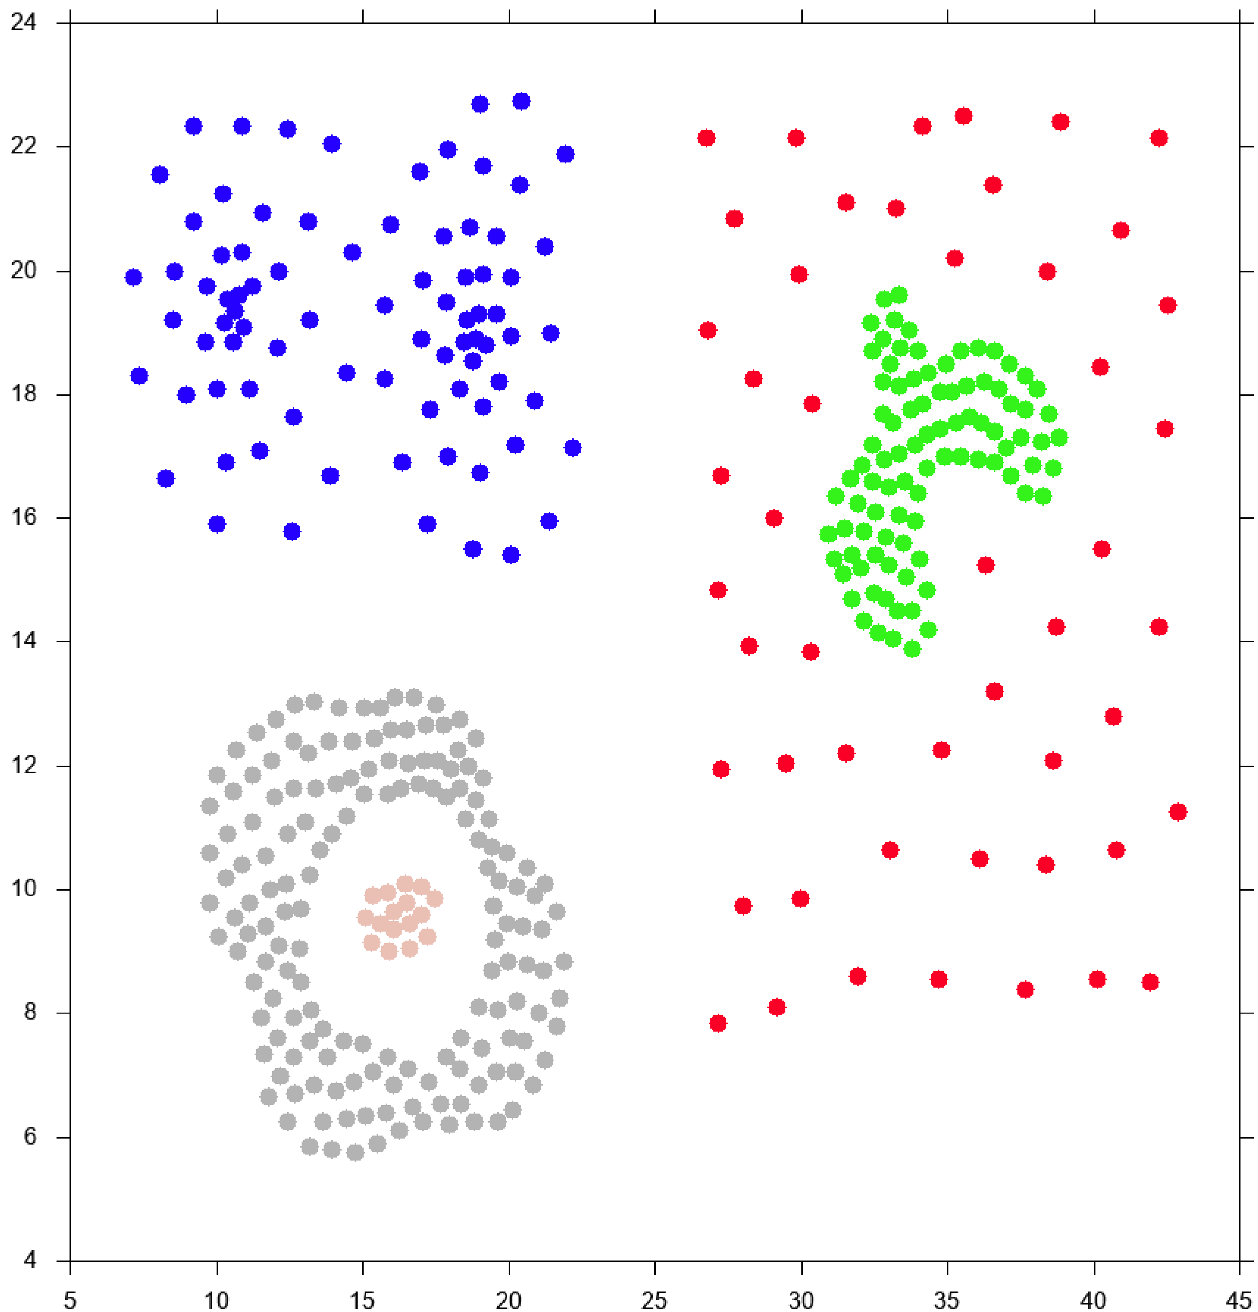
24
22
20
18
16
14
12
10
8
6
4
5
10
15
20
25
30
35
40
45

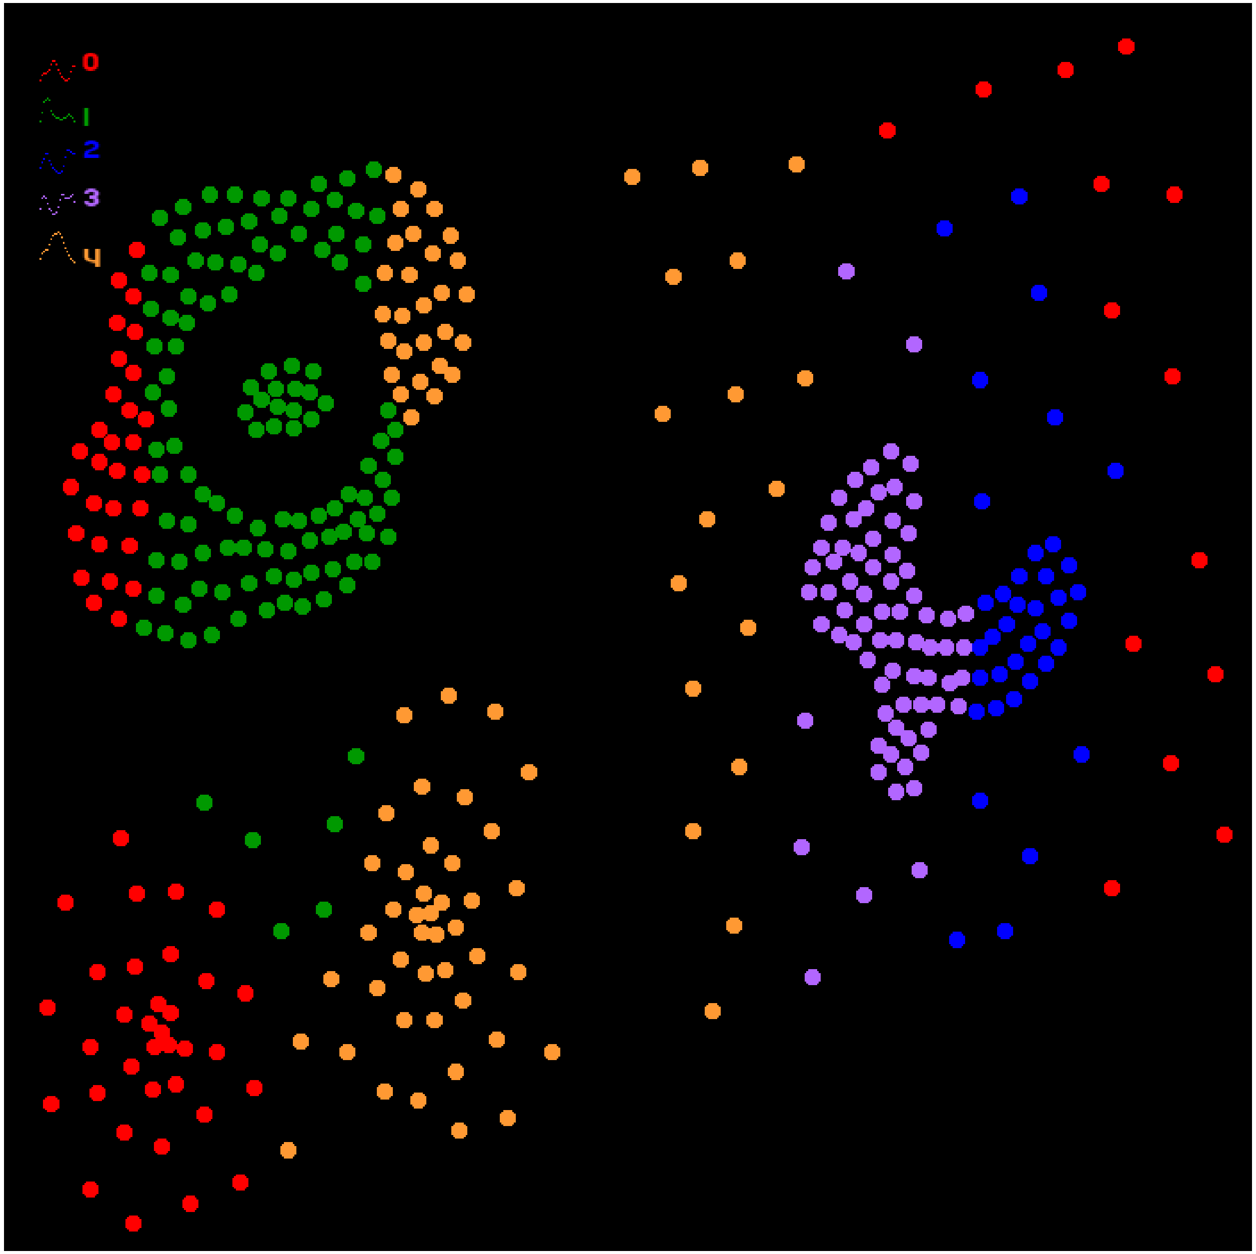

¿Cuál es el diámetro?

¿Qué tan aislado está el punto más aislado?

¿Cuál es la distancia típica al punto más cercano?

¿Existen cúmulos?

...

Matriz de atributos

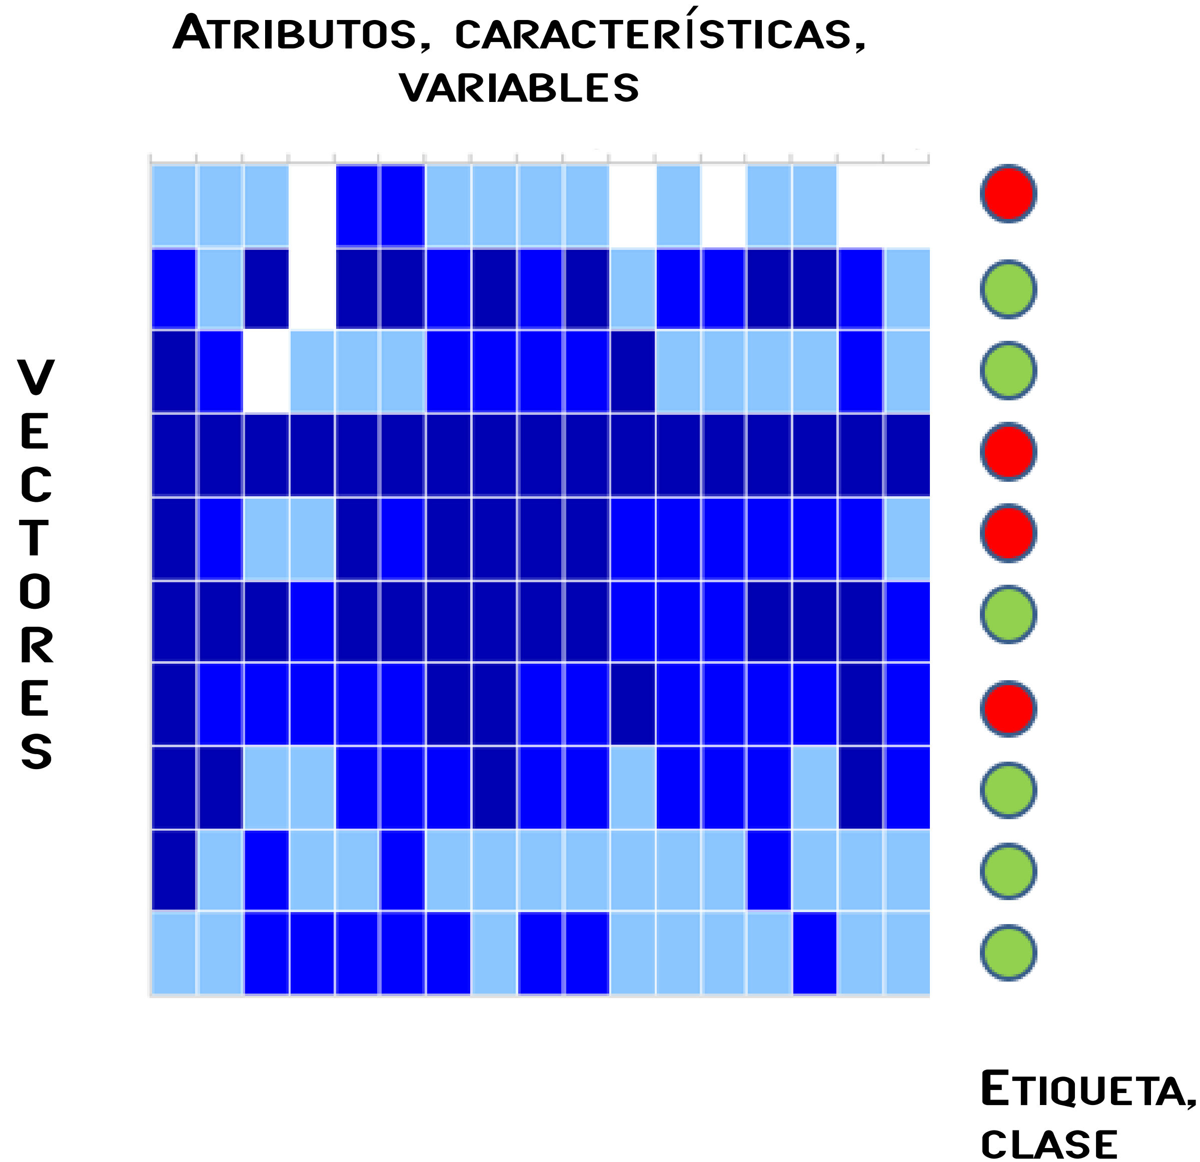

¿Qué podemos obtener del análisis exploratorio de datos?

Proyecciones (no lineales), mapeos

Cúmulos (Clusters)

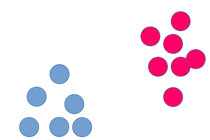

Áreas de baja densidad

Áreas de alta densidad

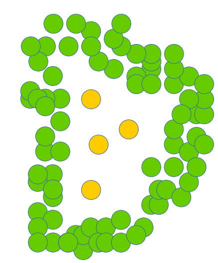

Anomalías

Vectores similares

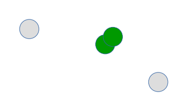

Vectors con vecindad semejante

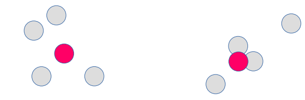

Correlaciones

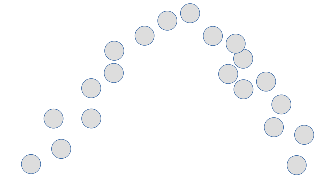

Variables relevantes
(¿Variedades topológicas?)

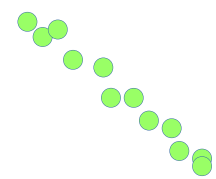

Bordes (Perímetro)

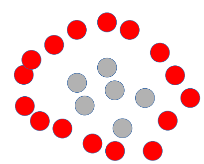

Ruido

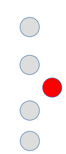

Perfiles típicos (“resúmenes”)

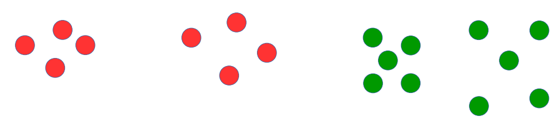

Algoritmos

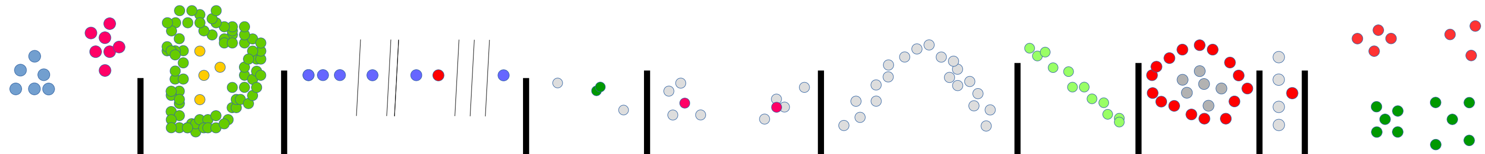

Escalares

Vectores de atributos
(media, desv. Std.)

Dendrogramas

Mapas de calor

PCA

ICA

Isomap

TSNE

SOM

TDA

PFN

LOF

Mundo...

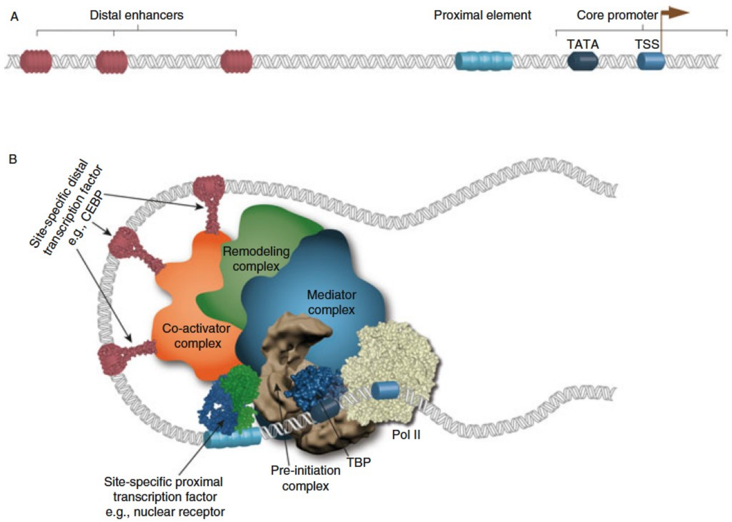

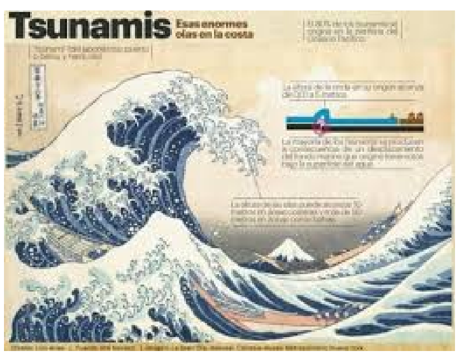

$f(\text{mundo}) \rightarrow \mathbb{R}^N$

A partir de aquí, queremos entender el mundo

Análisis exploratorio de datos (AED)

Sensores → Datos → "Información" → Predicción

AED

Prueba de hipótesis

Análisis confirmatorio de datos

“No clever manipulation of data can improve the inferences that can be made from the data”.

T.M. Cover and J.A. Thomas
Elements of Information Theory.
2006

Aprendizaje supervisado

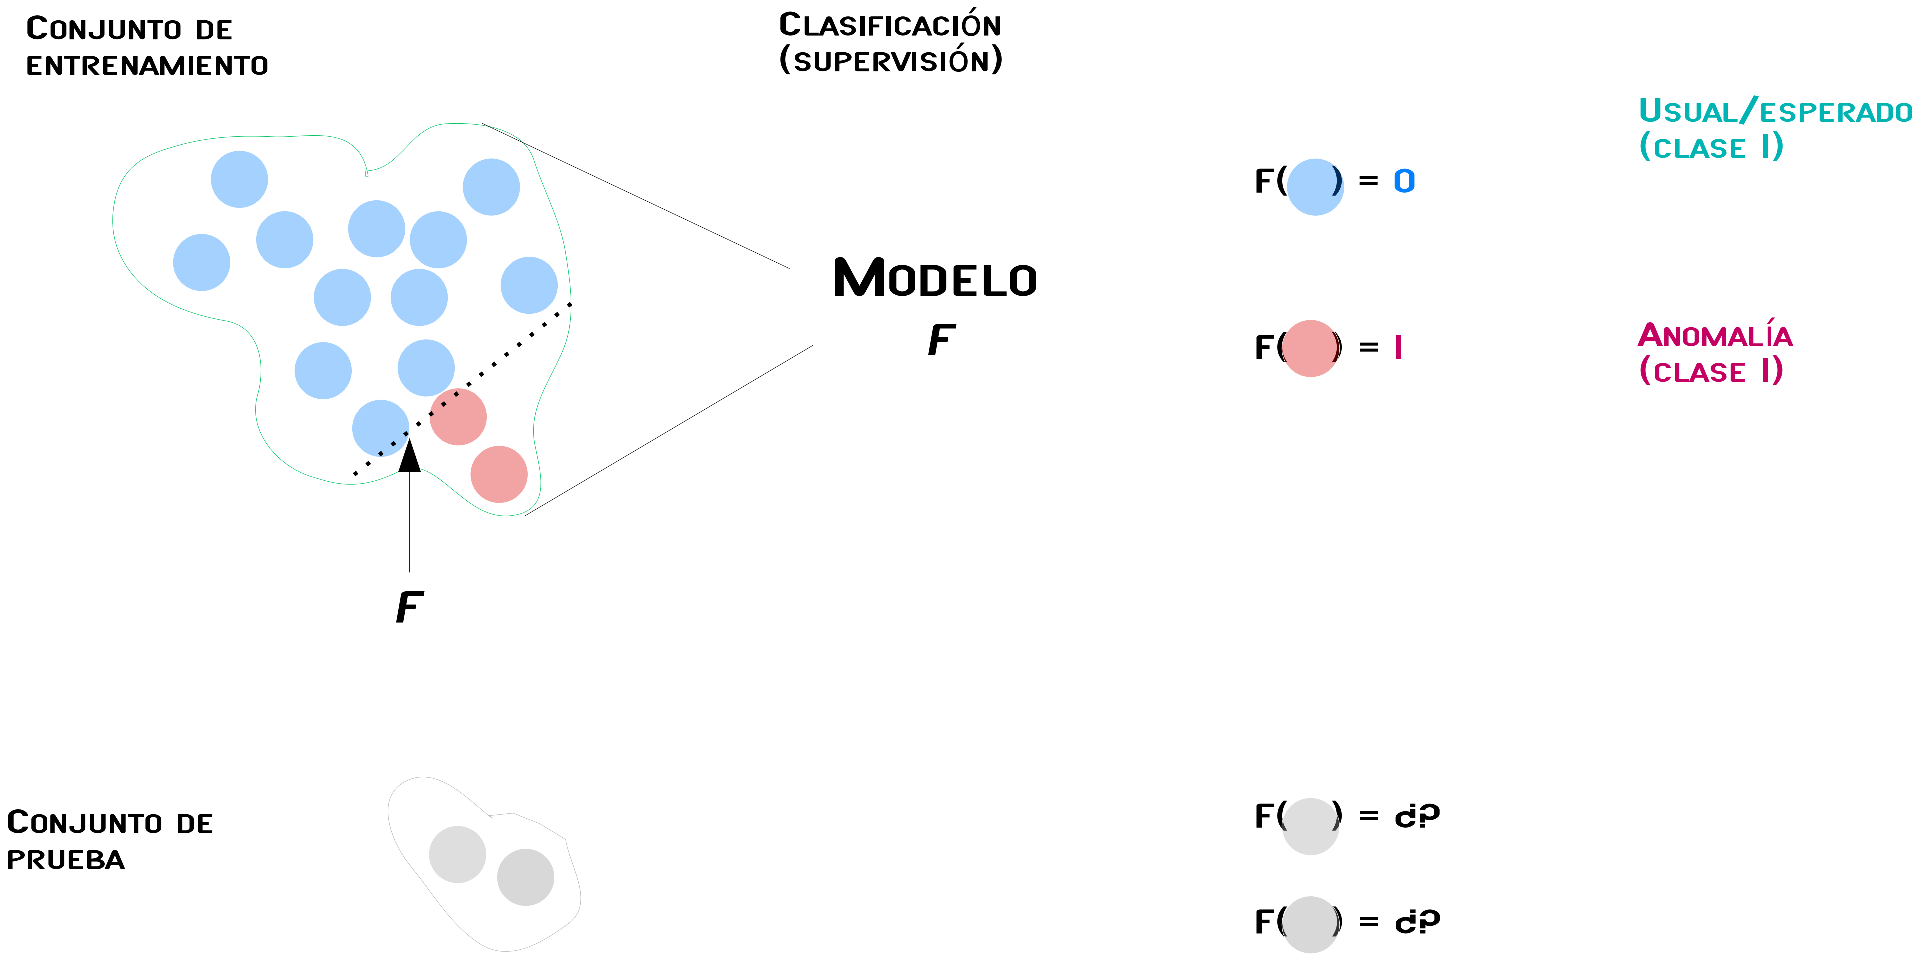

Aprendizaje no supervisado

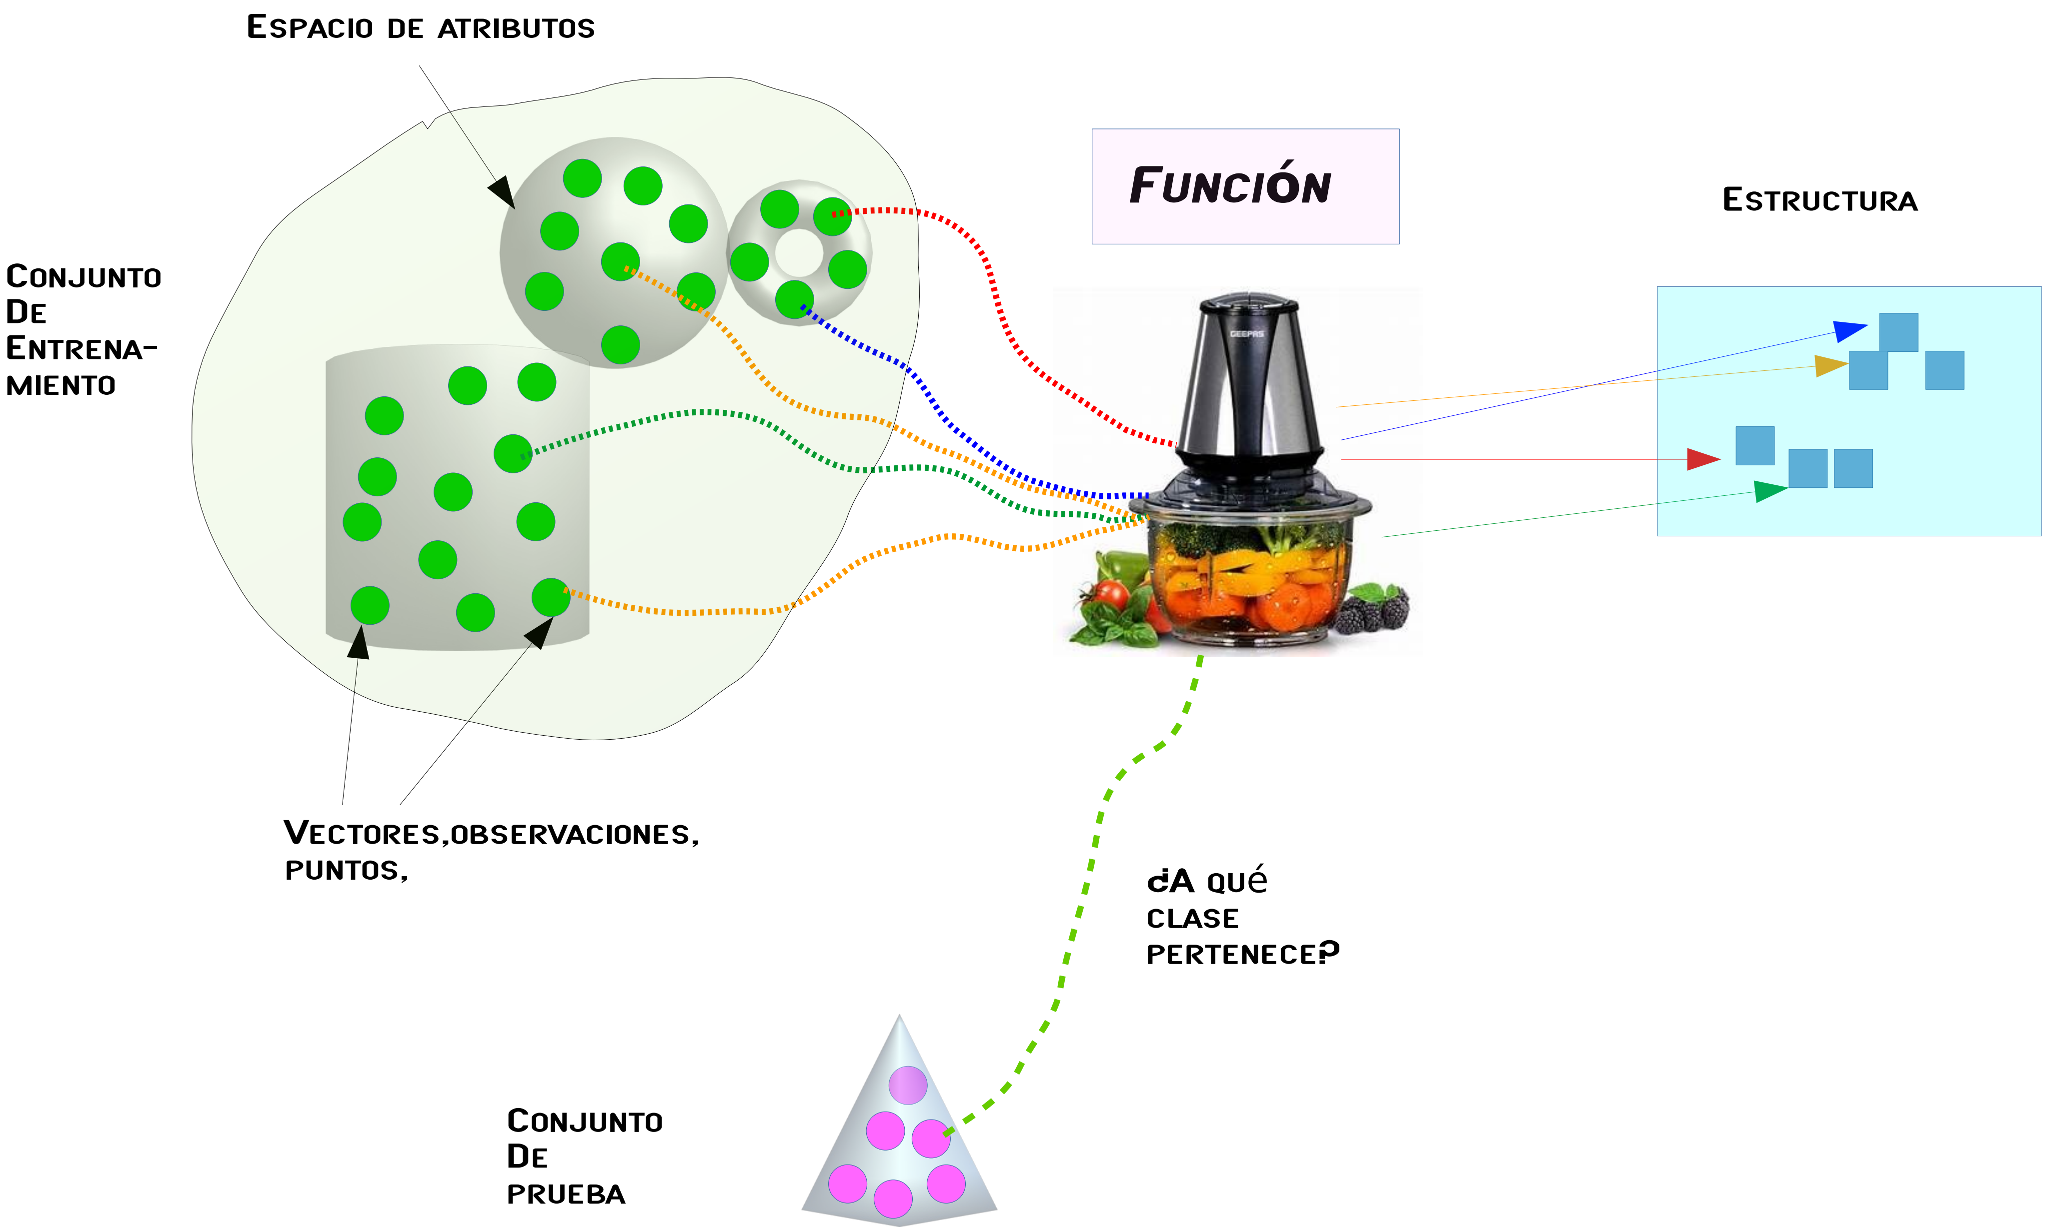

Espacios multidimensionales

The Strange Geometry of High-Dimensional Spaces (II)

The volume of a high-dimensional ball is concentrated in its crust!

Let us write $B_p(0,r)$ for the p-dimensional ball centered at 0 with radius $r > 0$, and $C_p(r)$ for the "crust" obtained by removing from $B_p(0,r)$ the sub-ball $B_p(0,0.99r)$. In other words, the "crust" gathers the points in $B_p(0,r)$, which are at a distance less than $0.01r$ from its surface.

In Figure 1.5, we plot as a function of p the ratio of the volume of $C_p(r)$ to the volume of $B_p(0,r)$

$$\frac{\text{volume}(C_p(r))}{\text{volume}(B_p(0,r))} = 1 - 0.99^p,$$

which goes exponentially fast to 1.

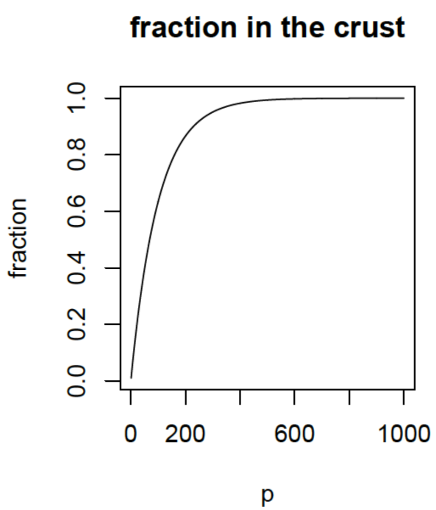

Figure 1.5

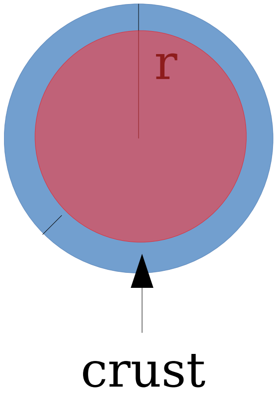

(Giraud, 2015)

FECHA_ACTUALIZACION ID_REGISTRO ORIGEN SECTOR ENTIDAD_UM SEXO ENTIDAD_NAC ENTIDAD_RES MUNICIPIO_RES TIPO_PACIENTE FECHA_INGRESO FECHA_SINTOMAS FECHA_DEF INTUBADO NEUMONIA EDAD NACIONALIDAD EMBARAZO HABLA_LENGUA_INDIG INDIGENA DIABETES EPOC ASMA INMUSUPR HIPERTENSION OTRA_COM CARDIOVASCULAR OBESIDAD RENAL_CRONICA TABAQUISMO OTRO_CASO TOMA_MUESTRA_LAB RESULTADO_LAB TOMA_MUESTRA_ANTIGENO RESULTADO_ANTIGENO CLASIFICACION_FINAL MIGRANTE PAIS_NACIONALIDAD PAIS_ORIGEN UCI

210127COVID19MEXICO.csv → 4,544,323

(28.01.21)

Referencias

Data science vs. statistics: two cultures?
Carmichael I, Marron S.
doi.org/10.1007/s42081-018-0009-3
(2018).

"No clever manipulation of data can improve the Inferences that can be made from the data".

T.M. Cover and J.A. Thomas
Elements of Information Theory.
2006

Thomas M. Cover (1938, 2012)

"There are no such things as applied sciences, only applications of science."

Louis Pasteur
(1822, 1895)

The milkmaid (1658)

The geographer (1669)

Girl with a pearl earring (1665)

Johannes Vermeer

Neerlandish proverbs (1559)

The triumph of dead (1562)

The tower of Babel (1563)

Peter Brueghel el viejo

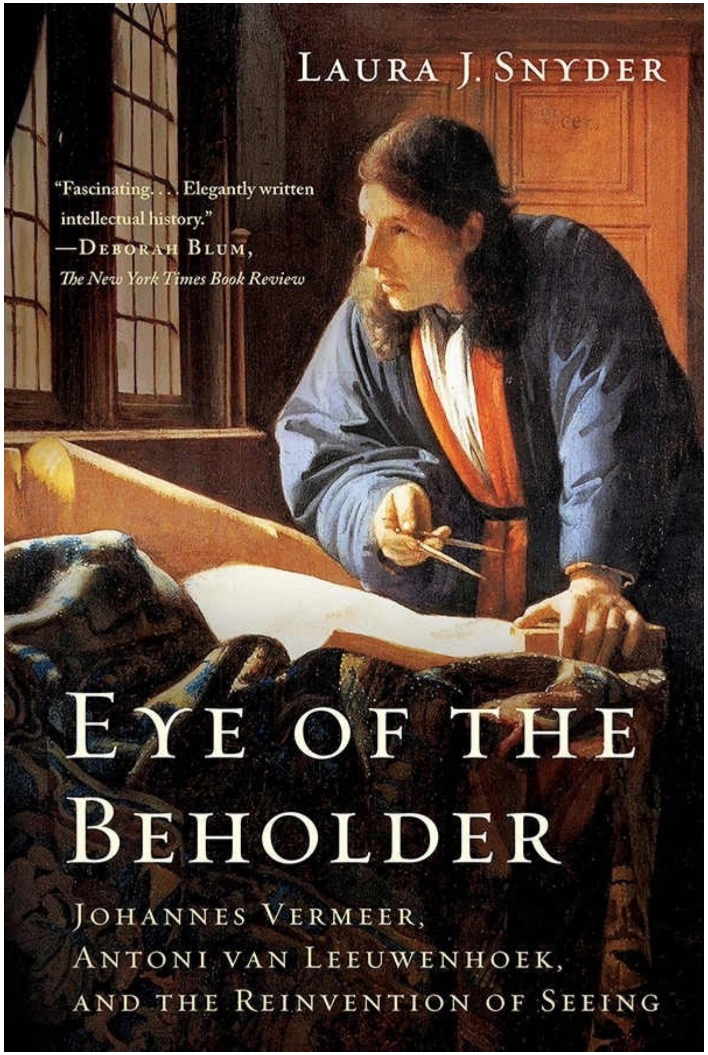

"... La gente era incapaz de entender lo que veía al microscopio"

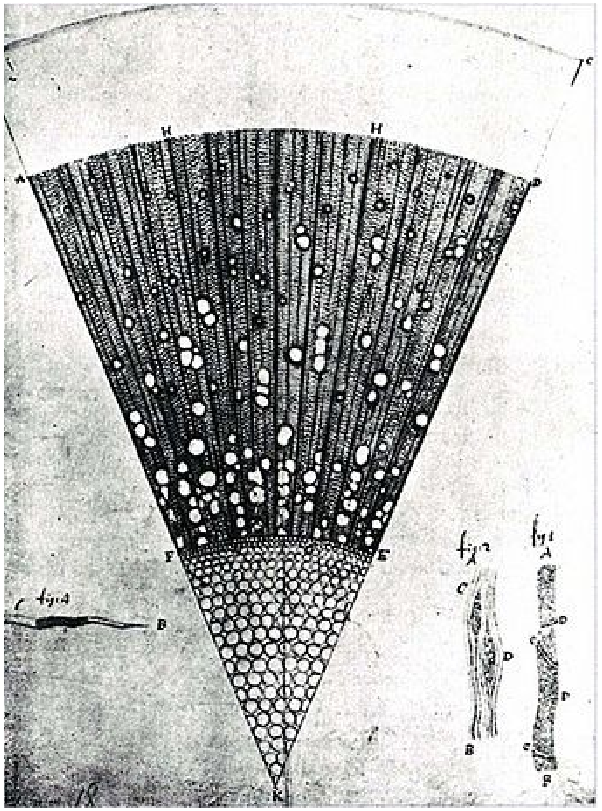

El caballo de batalla del semestre...

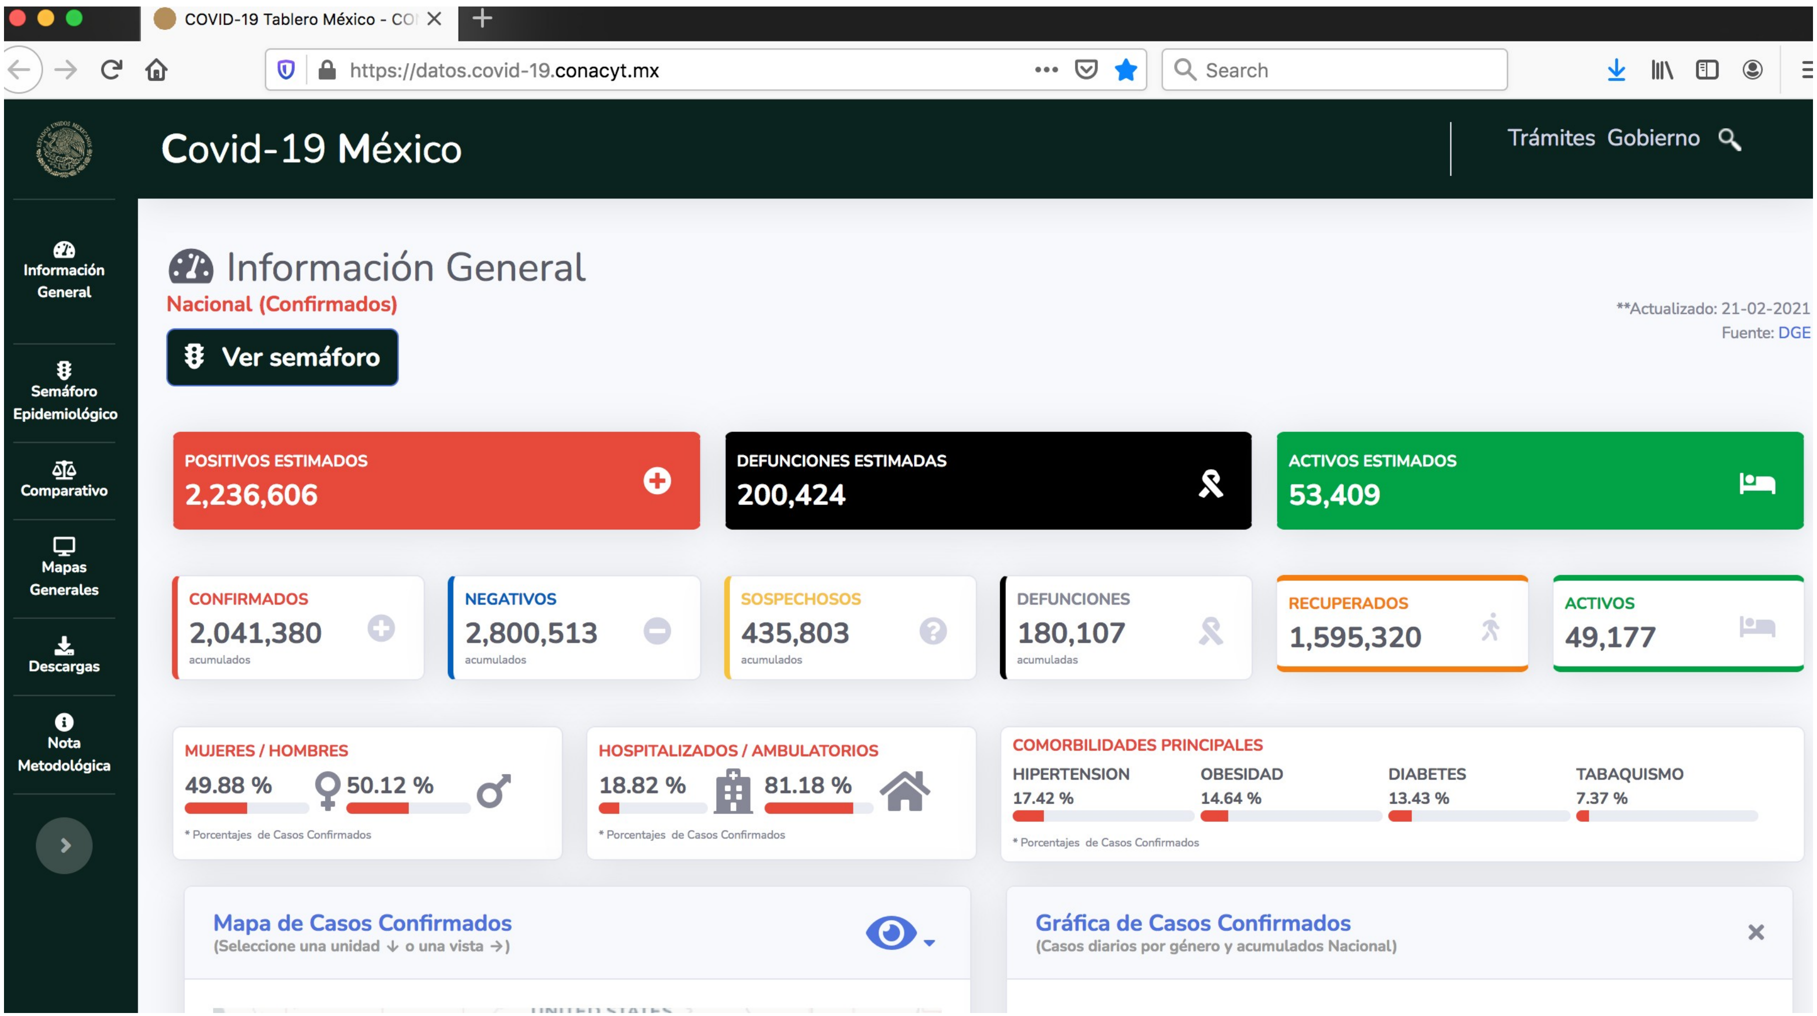

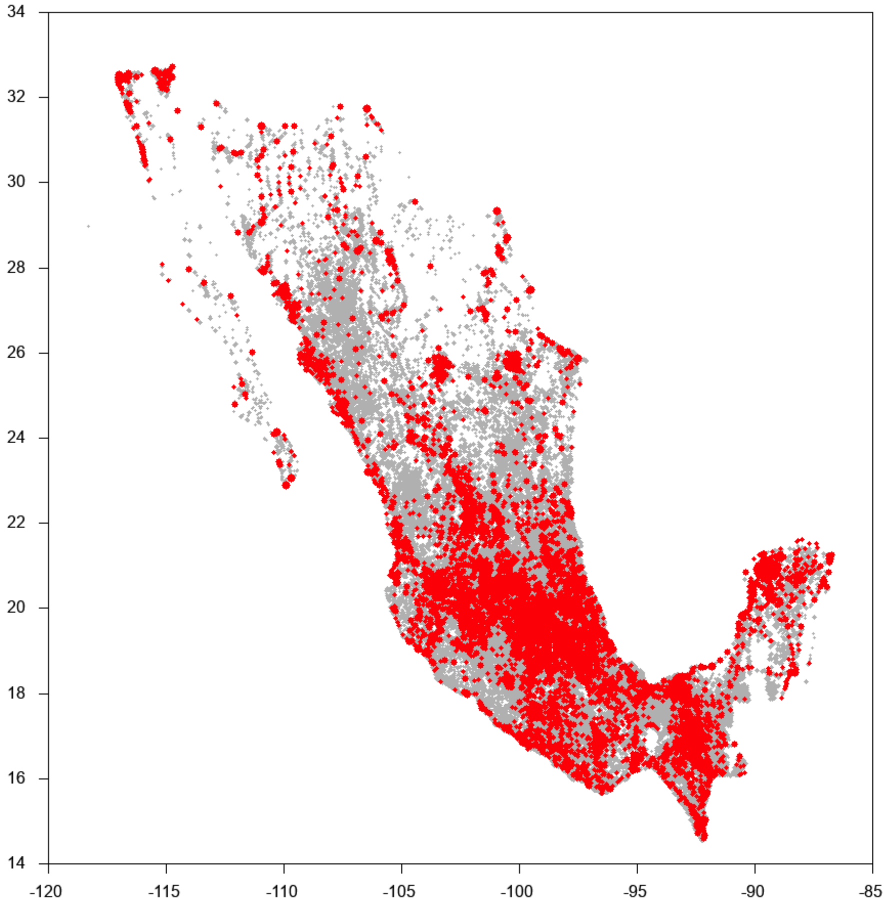
34
32
30
28
26
24
22
20
18
16
14
-120
-115
-110
-105
-100
-95
-90
-85

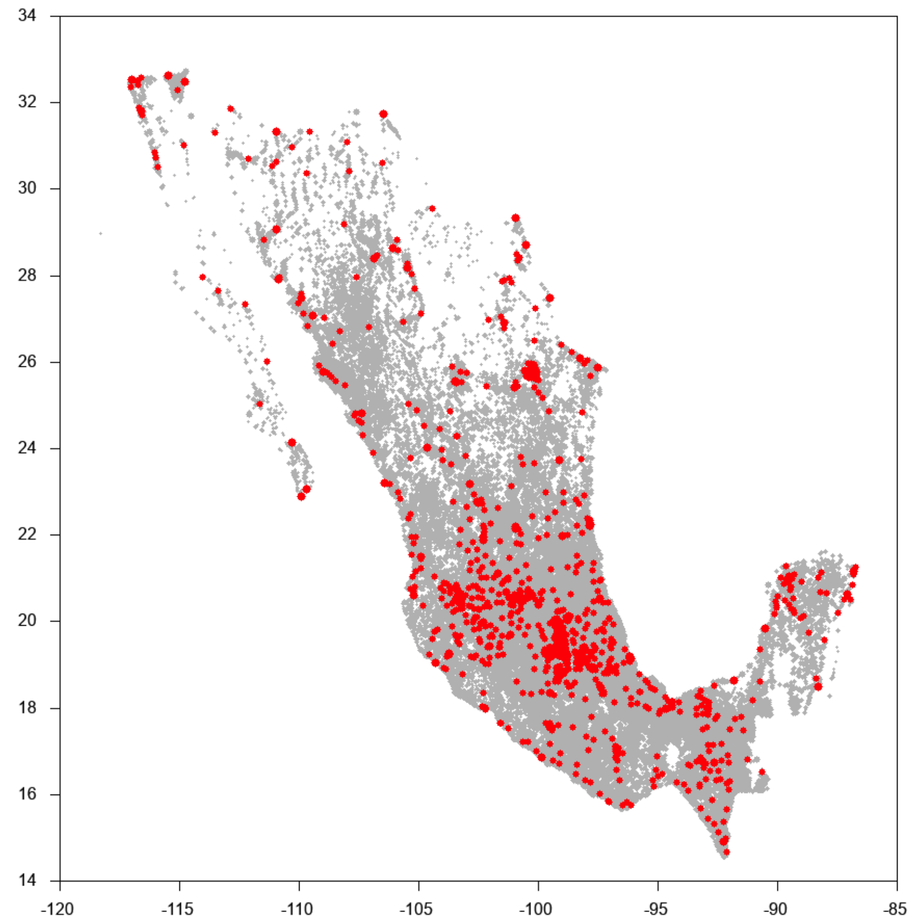
34
32
30
28
26
24
22
20
18
16
14
-120
-115
-110
-105
-100
-95
-90
-85

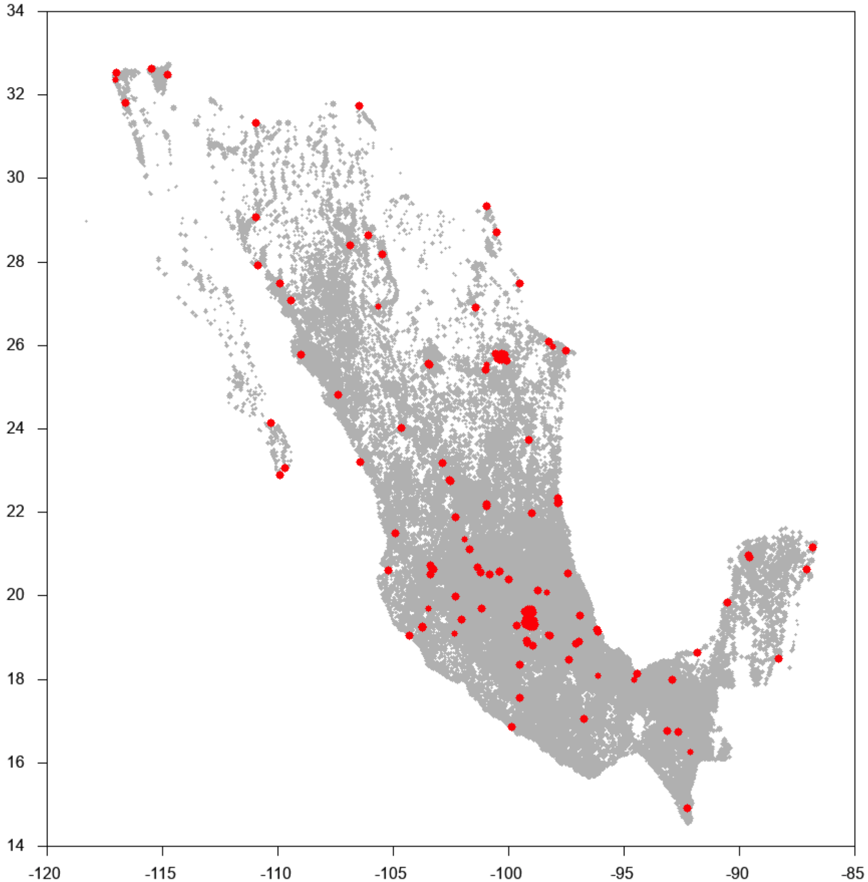

HTTPS://WWW.INEGI.ORG.MX/APP/AGEEML/

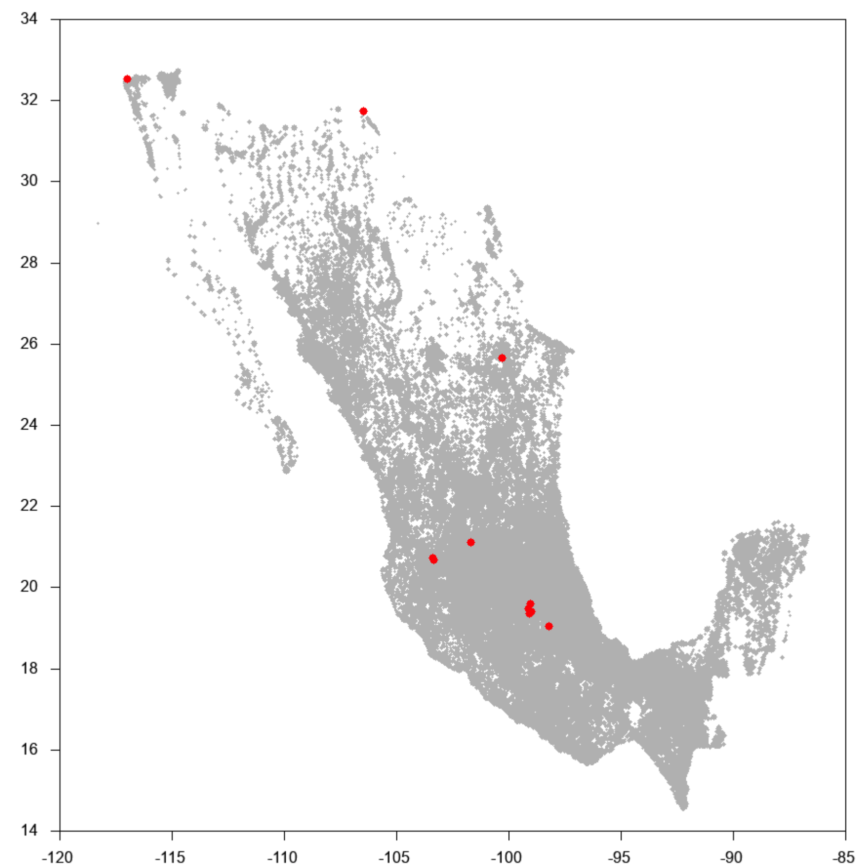

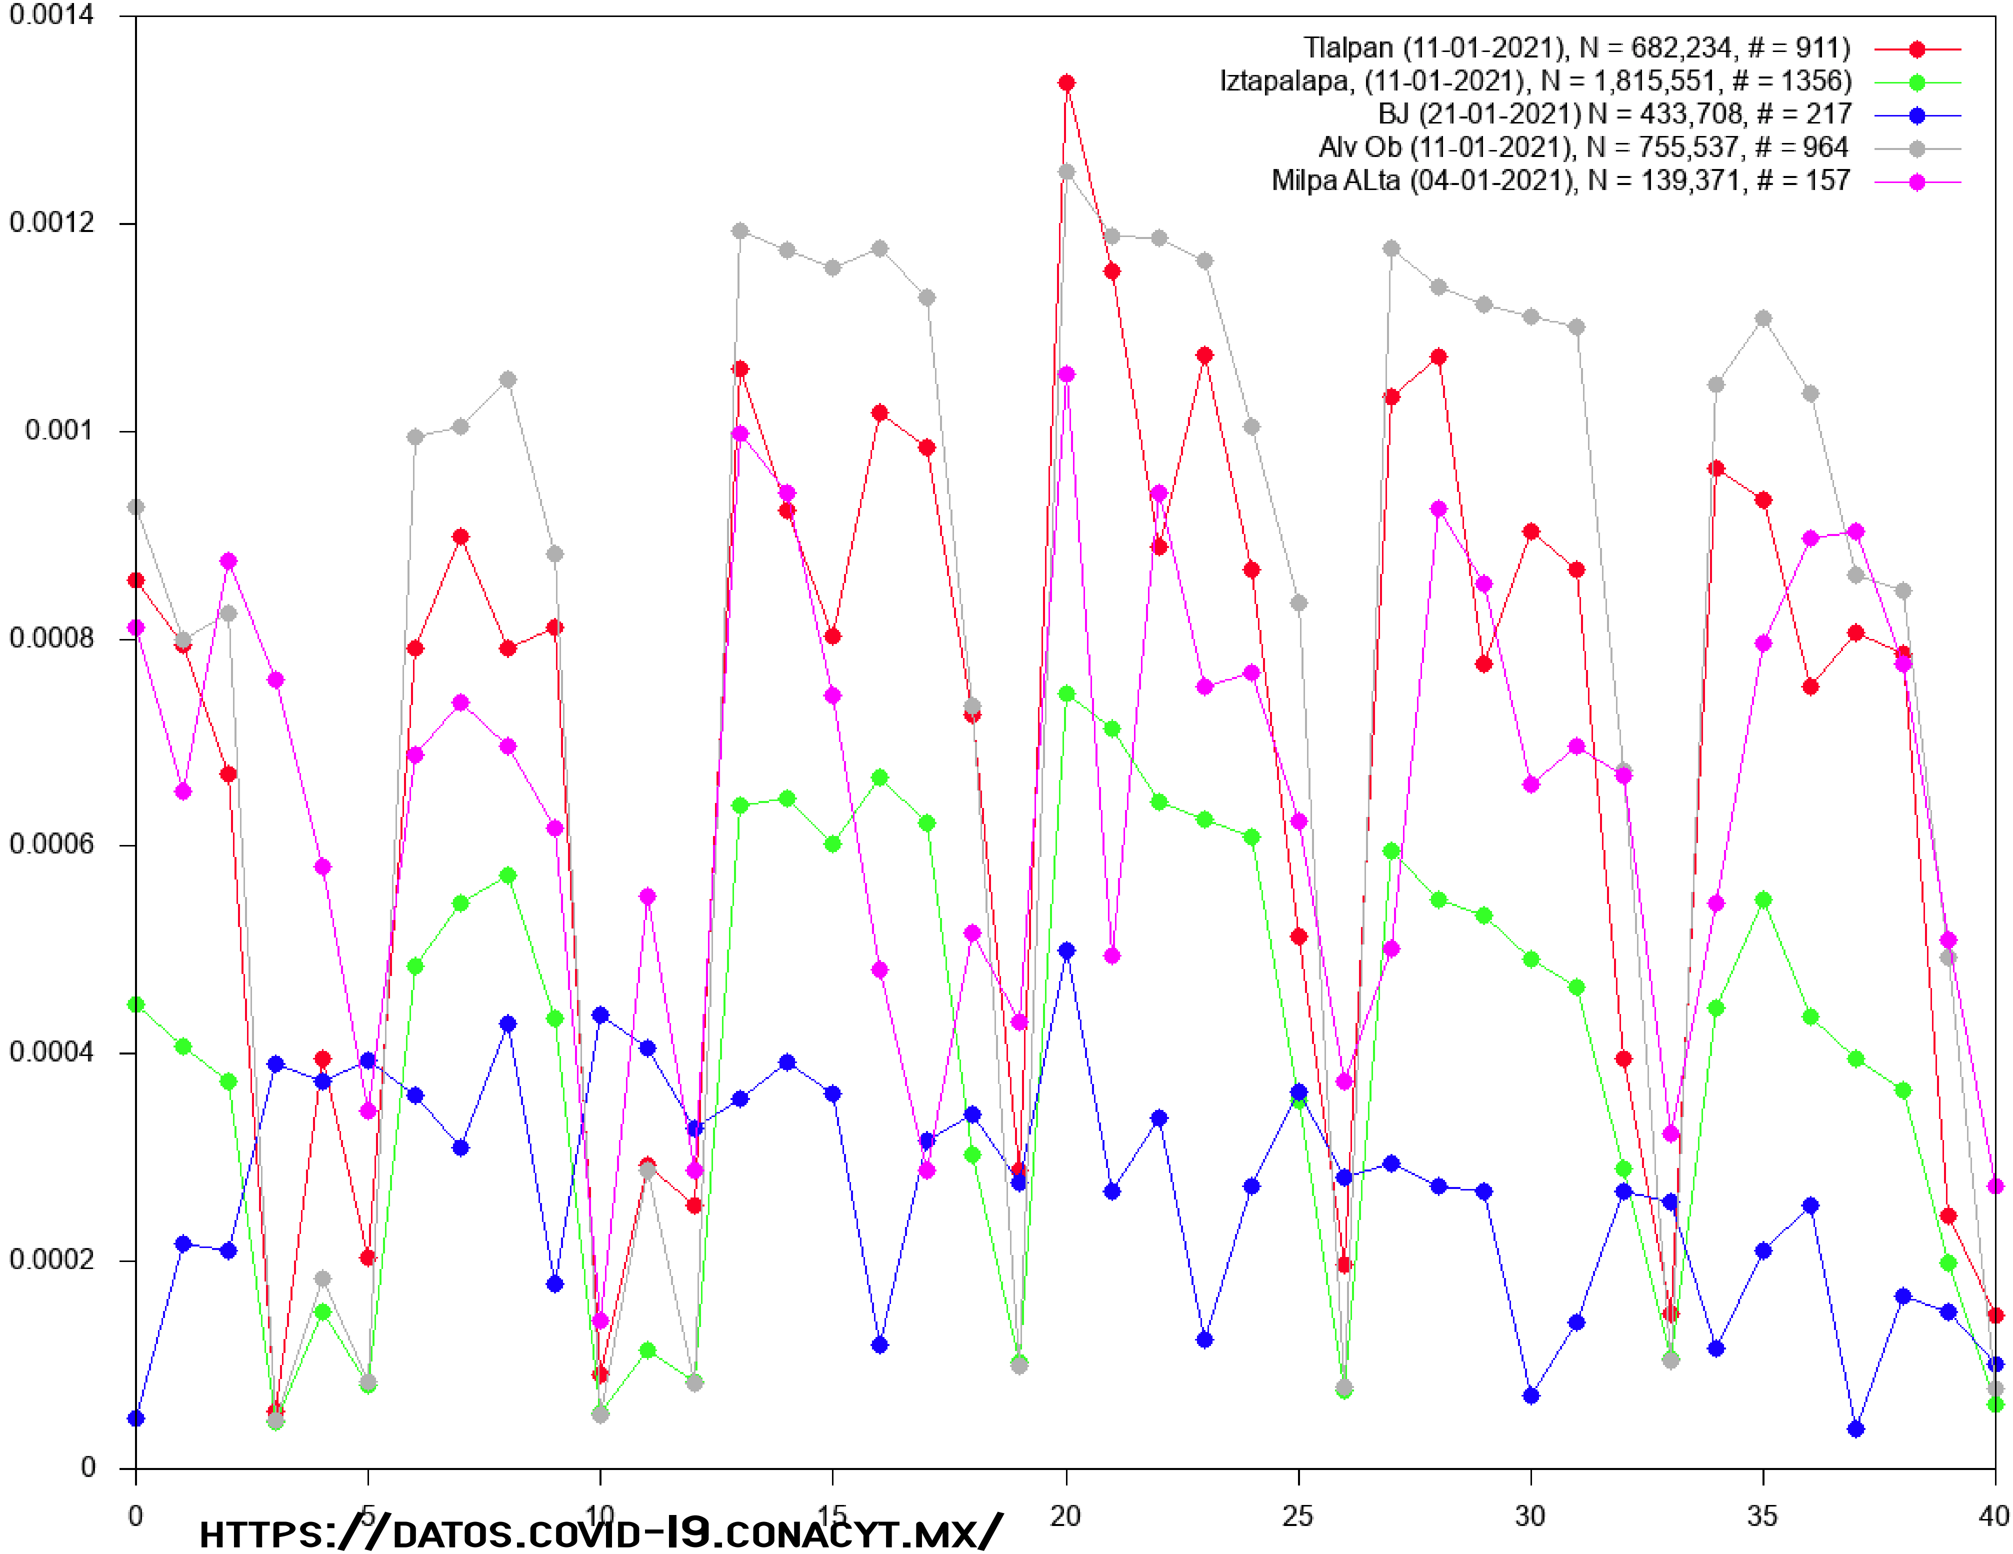
Tlalpan (11-01-2021), N = 682,234, # = 911)
Iztapalapa, (11-01-2021), N = 1,815,551, # = 1356)
BJ (21-01-2021) N = 433,708, # = 217
Alv Ob (11-01-2021), N = 755,537, # = 964
Milpa ALta (04-01-2021), N = 139,371, # = 157
0.0014
0.0012
0.001
0.0008
0.0006
0.0004
0.0002
0
0
5
10
15
20
25
30
35
40
HTTPS://DATOS.COVID-19.CONACYT.MX/

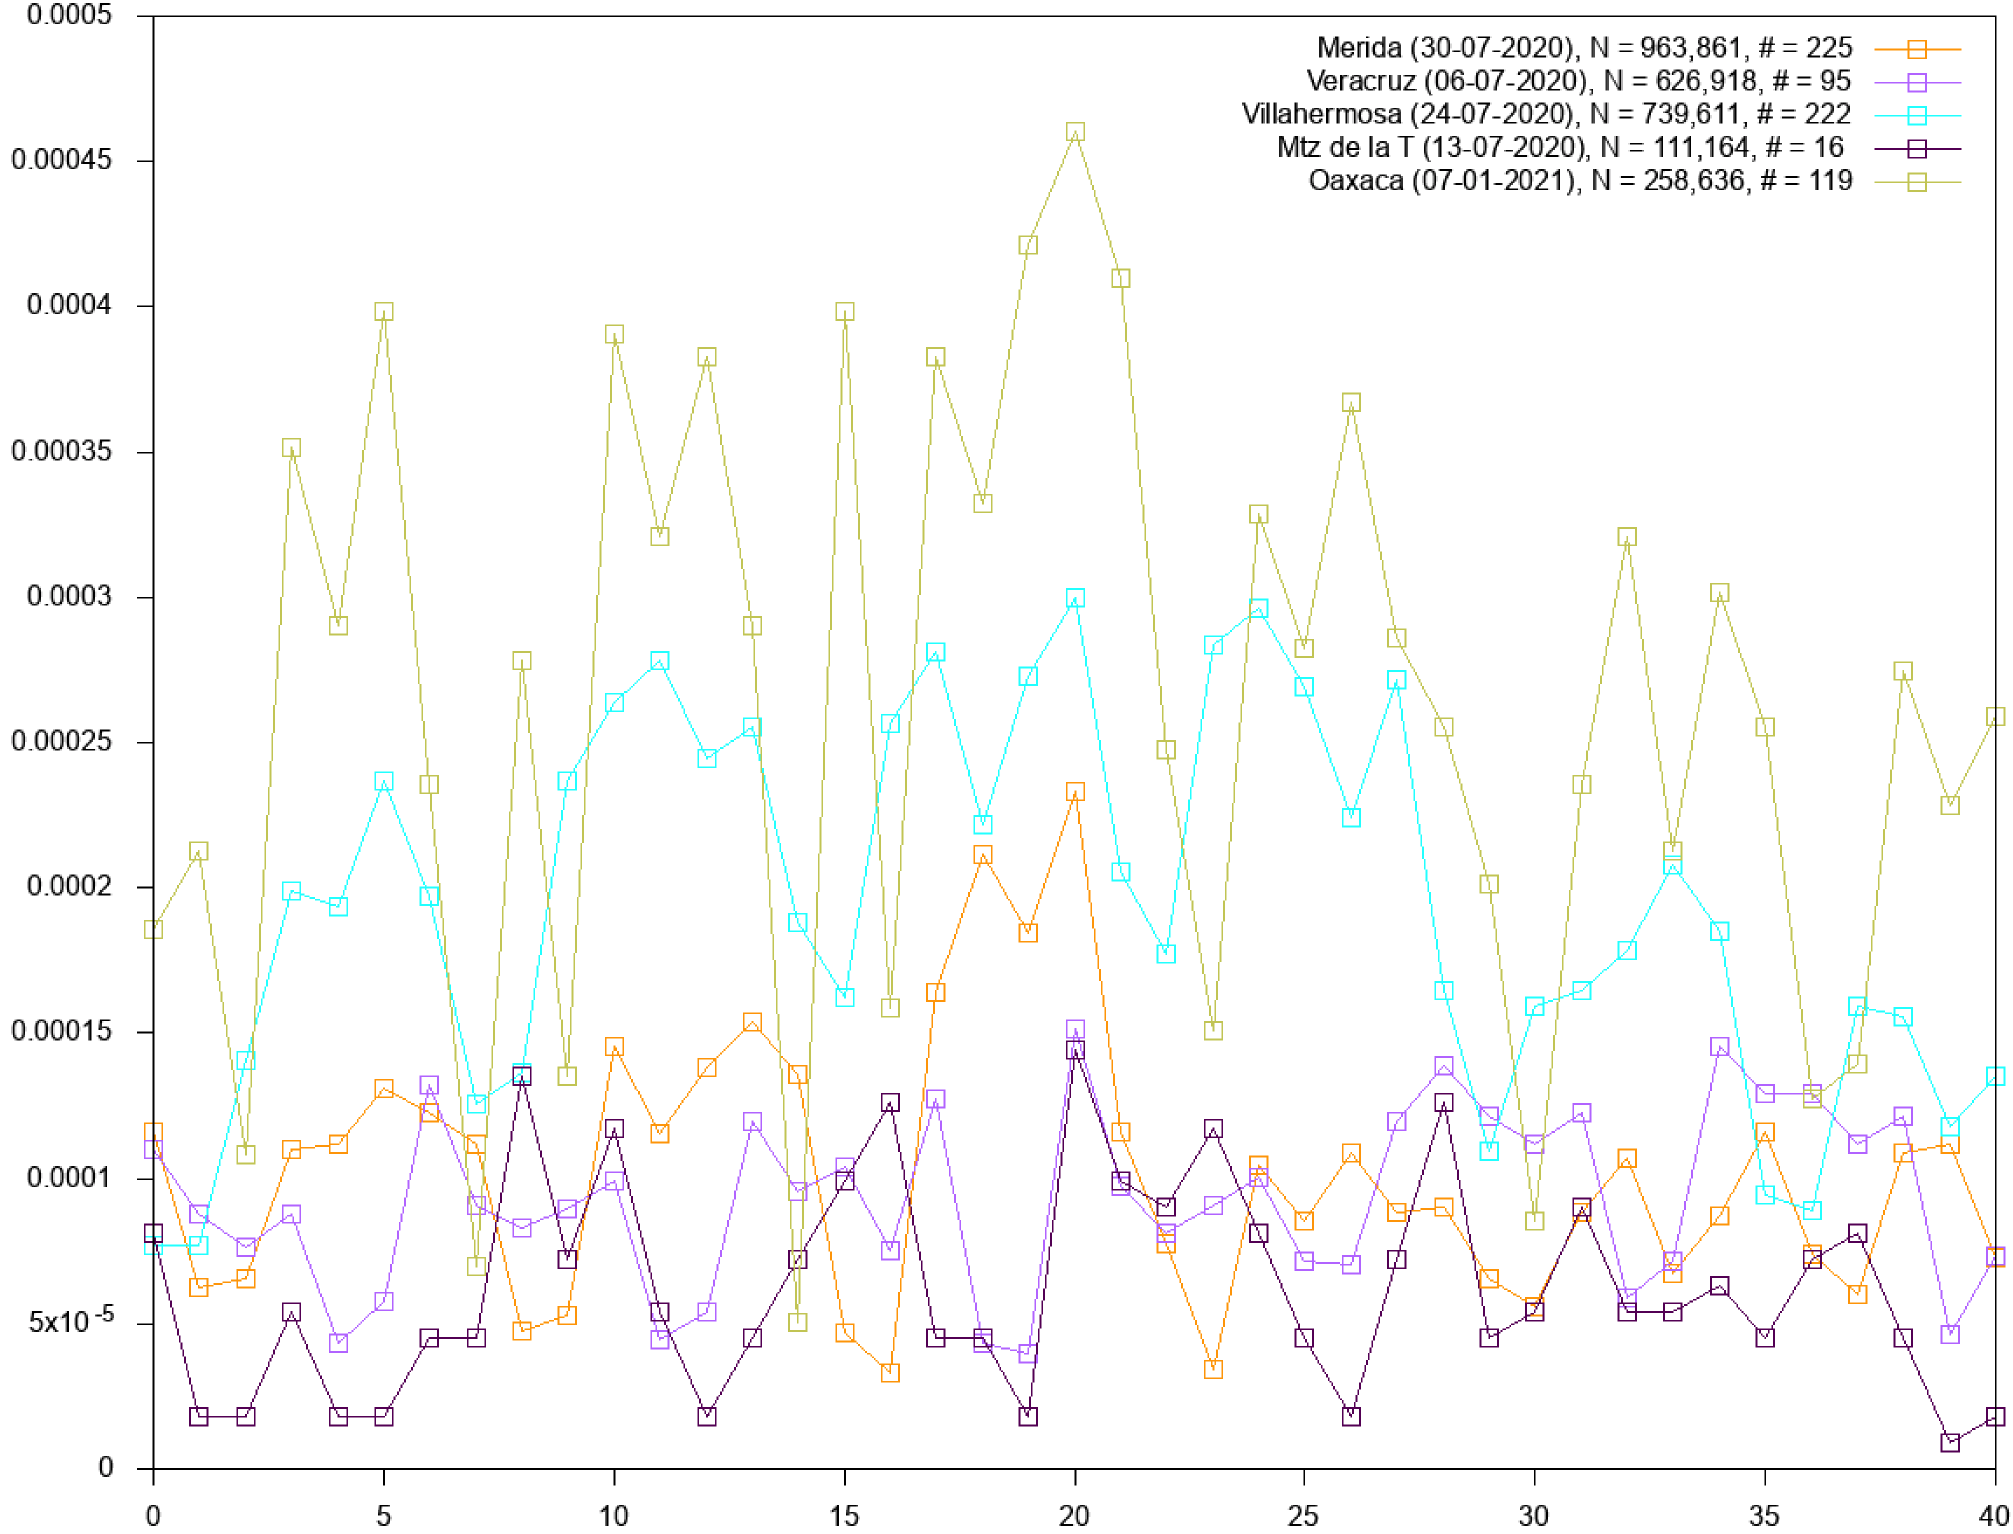
Merida (30-07-2020), N = 963,861, # = 225
Veracruz (06-07-2020), N = 626,918, # = 95
Villahermosa (24-07-2020), N = 739,611, # = 222
Mtz de la T (13-07-2020), N = 111,164, # = 16
Oaxaca (07-01-2021), N = 258,636, # = 119
0.0005
0.00045
0.0004
0.00035
0.0003
0.00025
0.0002
0.00015
0.0001
5x10 -5
0
0
5
10
15
20
25
30
35
40

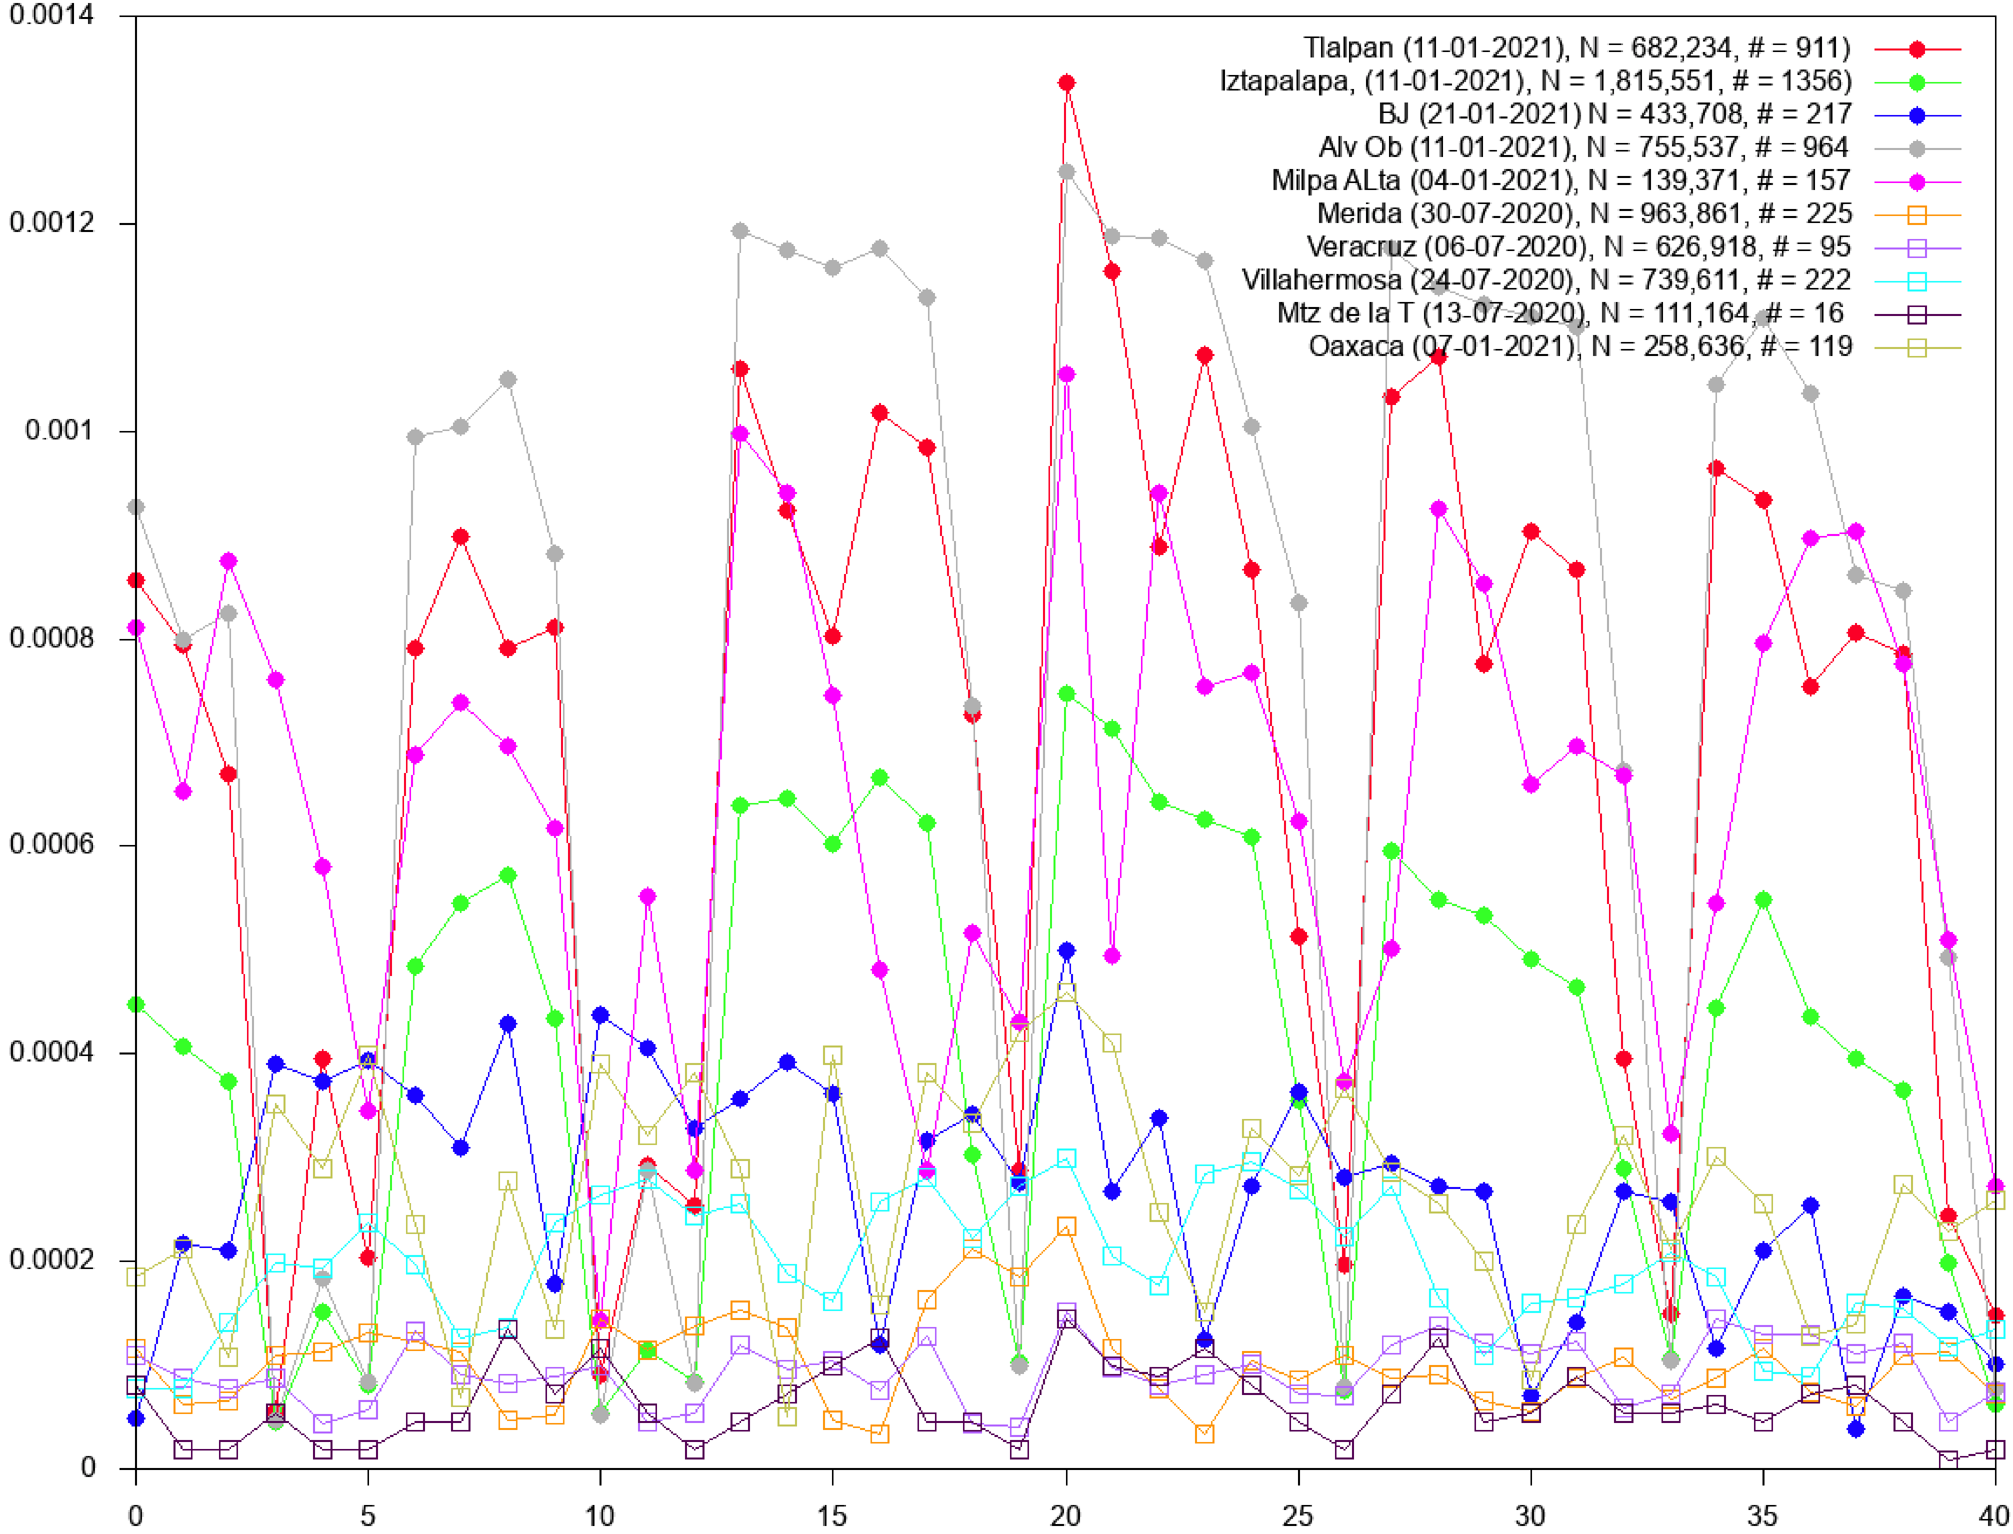
Tlalpan (11-01-2021), N = 682,234, # = 911
Iztapalapa, (11-01-2021), N = 1,815,551, # = 1356
BJ (21-01-2021) N = 433,708, # = 217
Alv Ob (11-01-2021), N = 755,537, # = 964
Milpa ALta (04-01-2021), N = 139,371, # = 157
Merida (30-07-2020), N = 963,861, # = 225
Veracruz (06-07-2020), N = 626,918, # = 95
Villahermosa (24-07-2020), N = 739,611, # = 222
Mtz de la T (13-07-2020), N = 111,164, # = 16
Oaxaca (07-01-2021), N = 258,636, # = 119
0.0014
0.0012
0.001
0.0008
0.0006
0.0004
0.0002
0
0
5
10
15
20
25
30
35
40

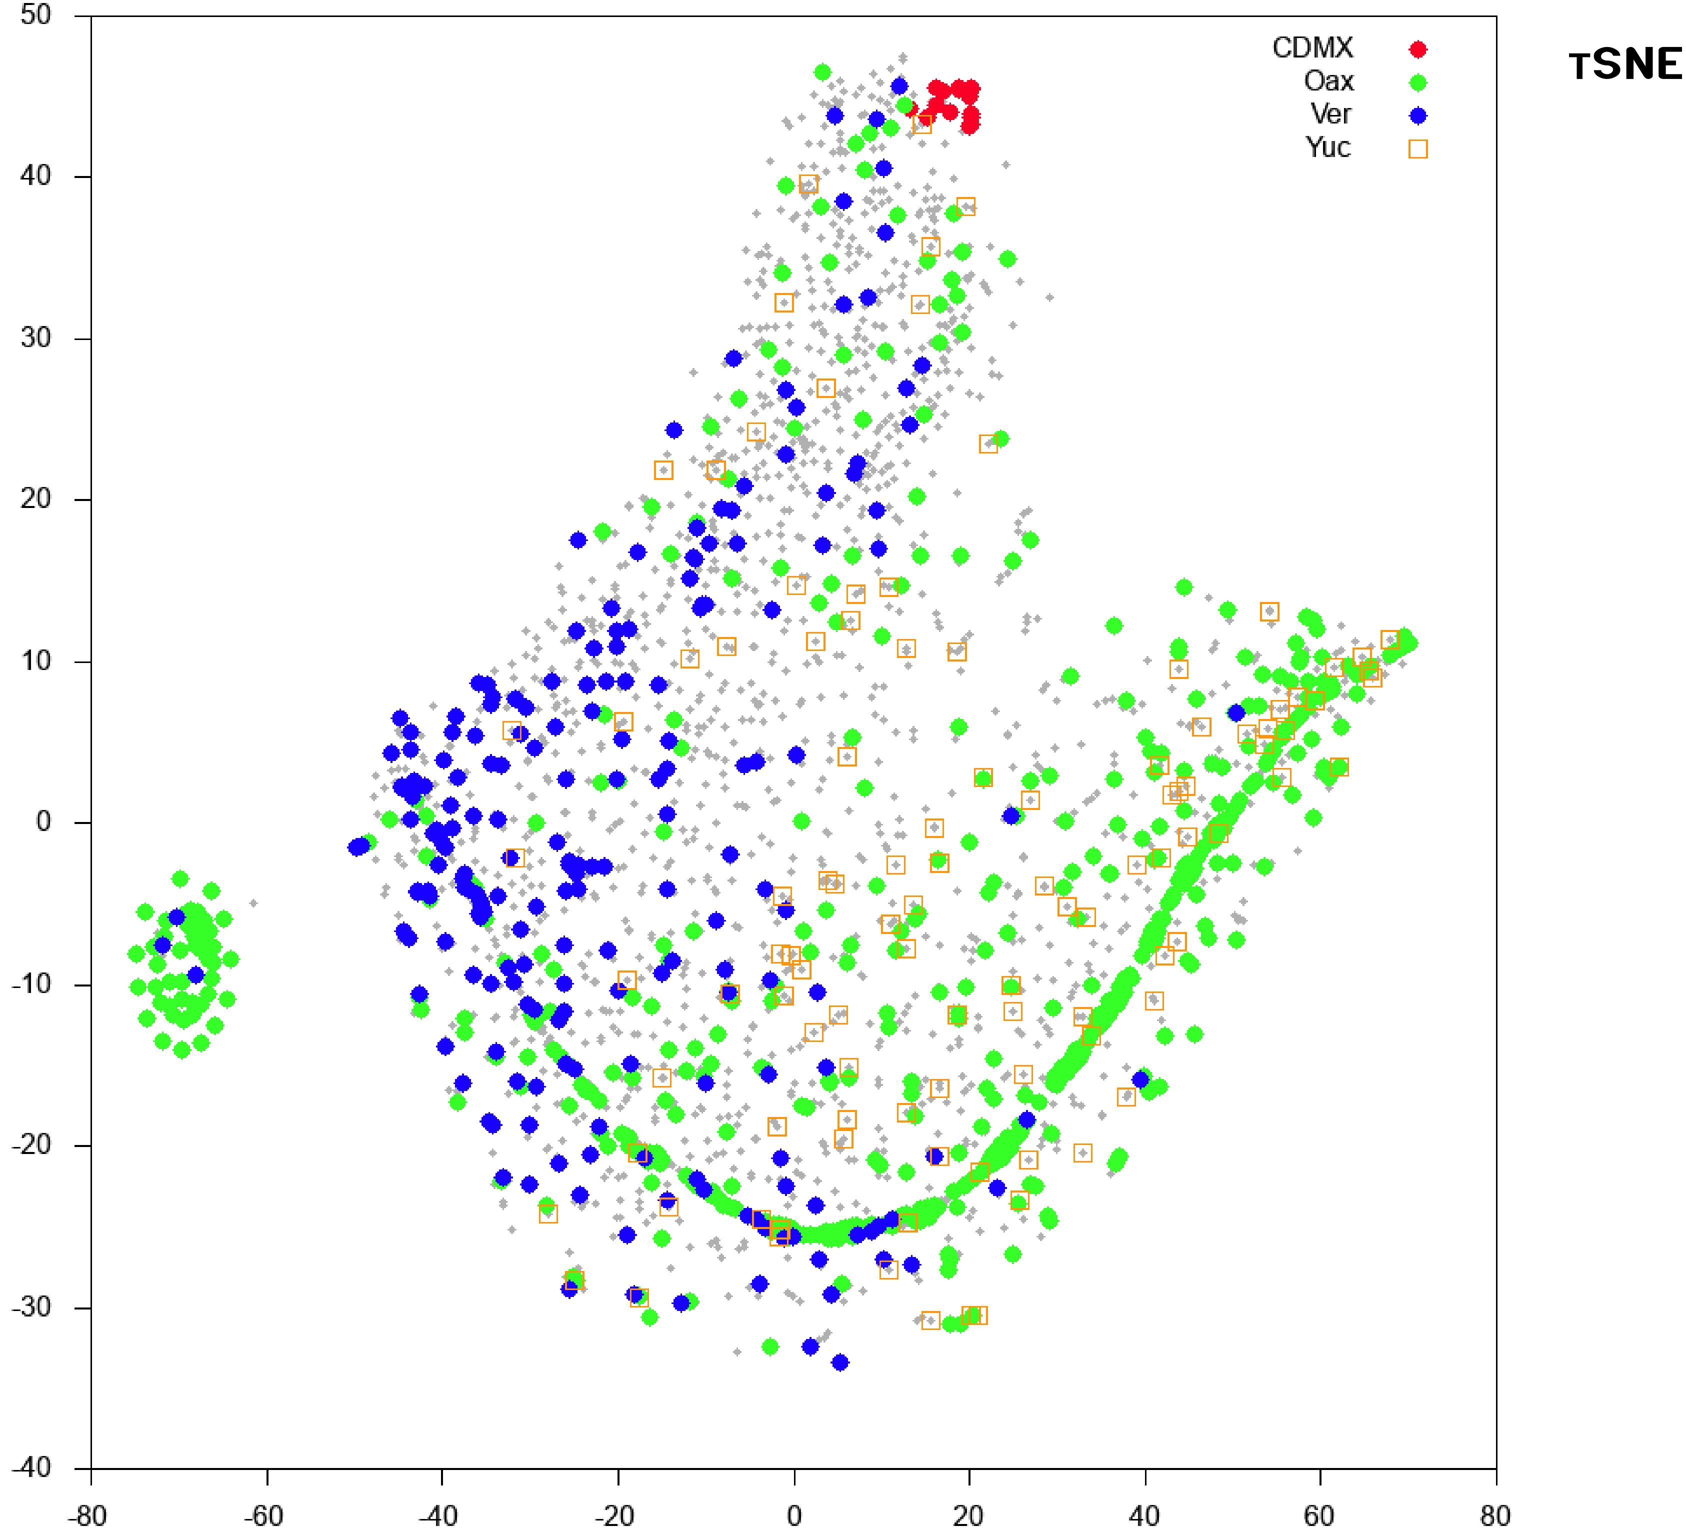
tSNE
CDMX
Oax
Ver
Yuc
50
40
30
20
10
0
-10
-20
-30
-40
-80
-60
-40
-20
0
20
40
60
80

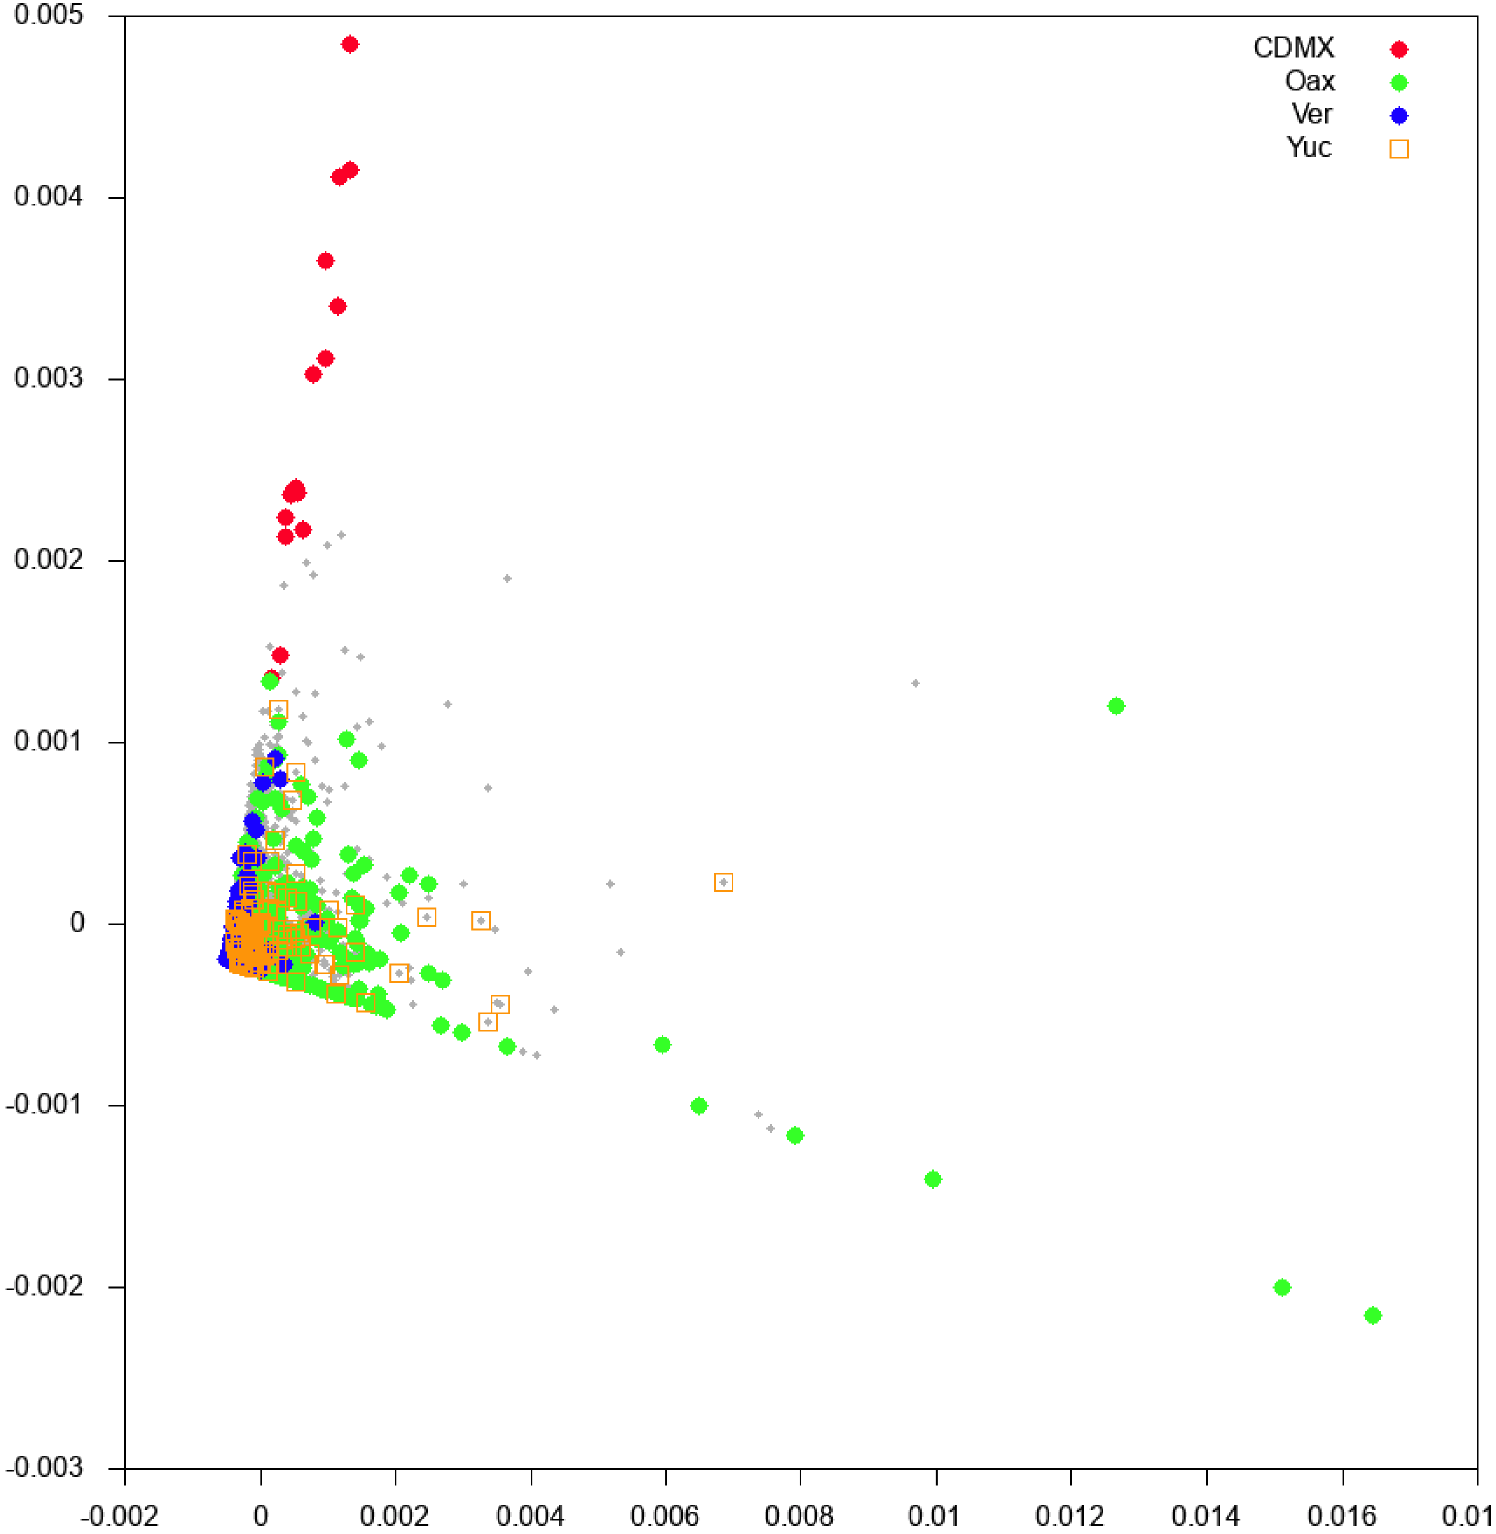

CDMX
Oax
Ver
Yuc
0.005
0.004
0.003
0.002
0.001
0
-0.001
-0.002
-0.003
-0.002
0
0.002
0.004
0.006
0.008
0.01
0.012
0.014
0.016
0.018

PCA

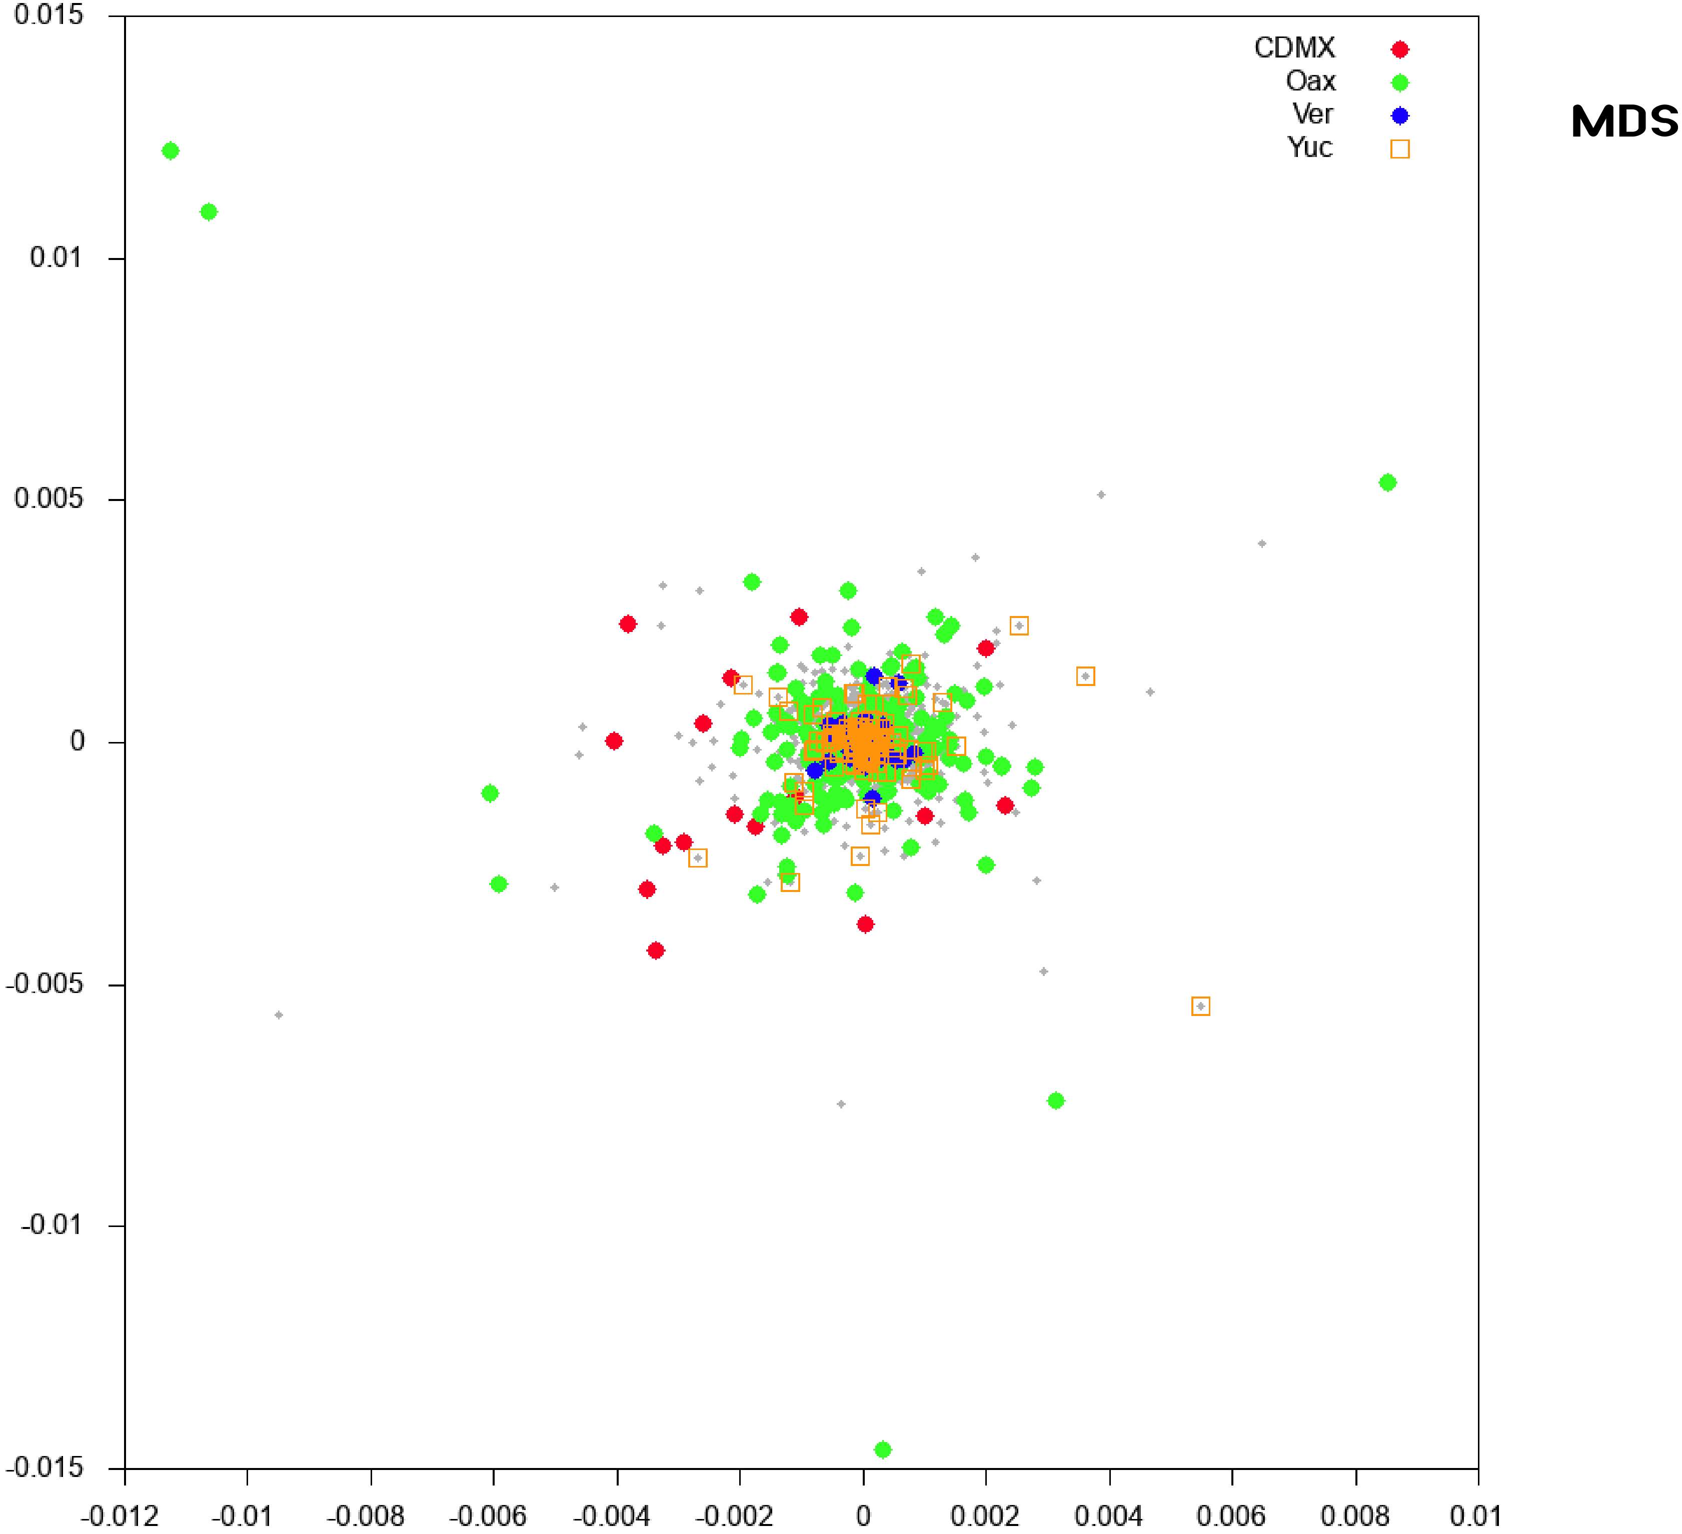

MDS
CDMX
Oax
Ver
Yuc
0.015
0.01
0.005
0
-0.005
-0.01
-0.015
-0.012
-0.01
-0.008
-0.006
-0.004
-0.002
0
0.002
0.004
0.006
0.008
0.01

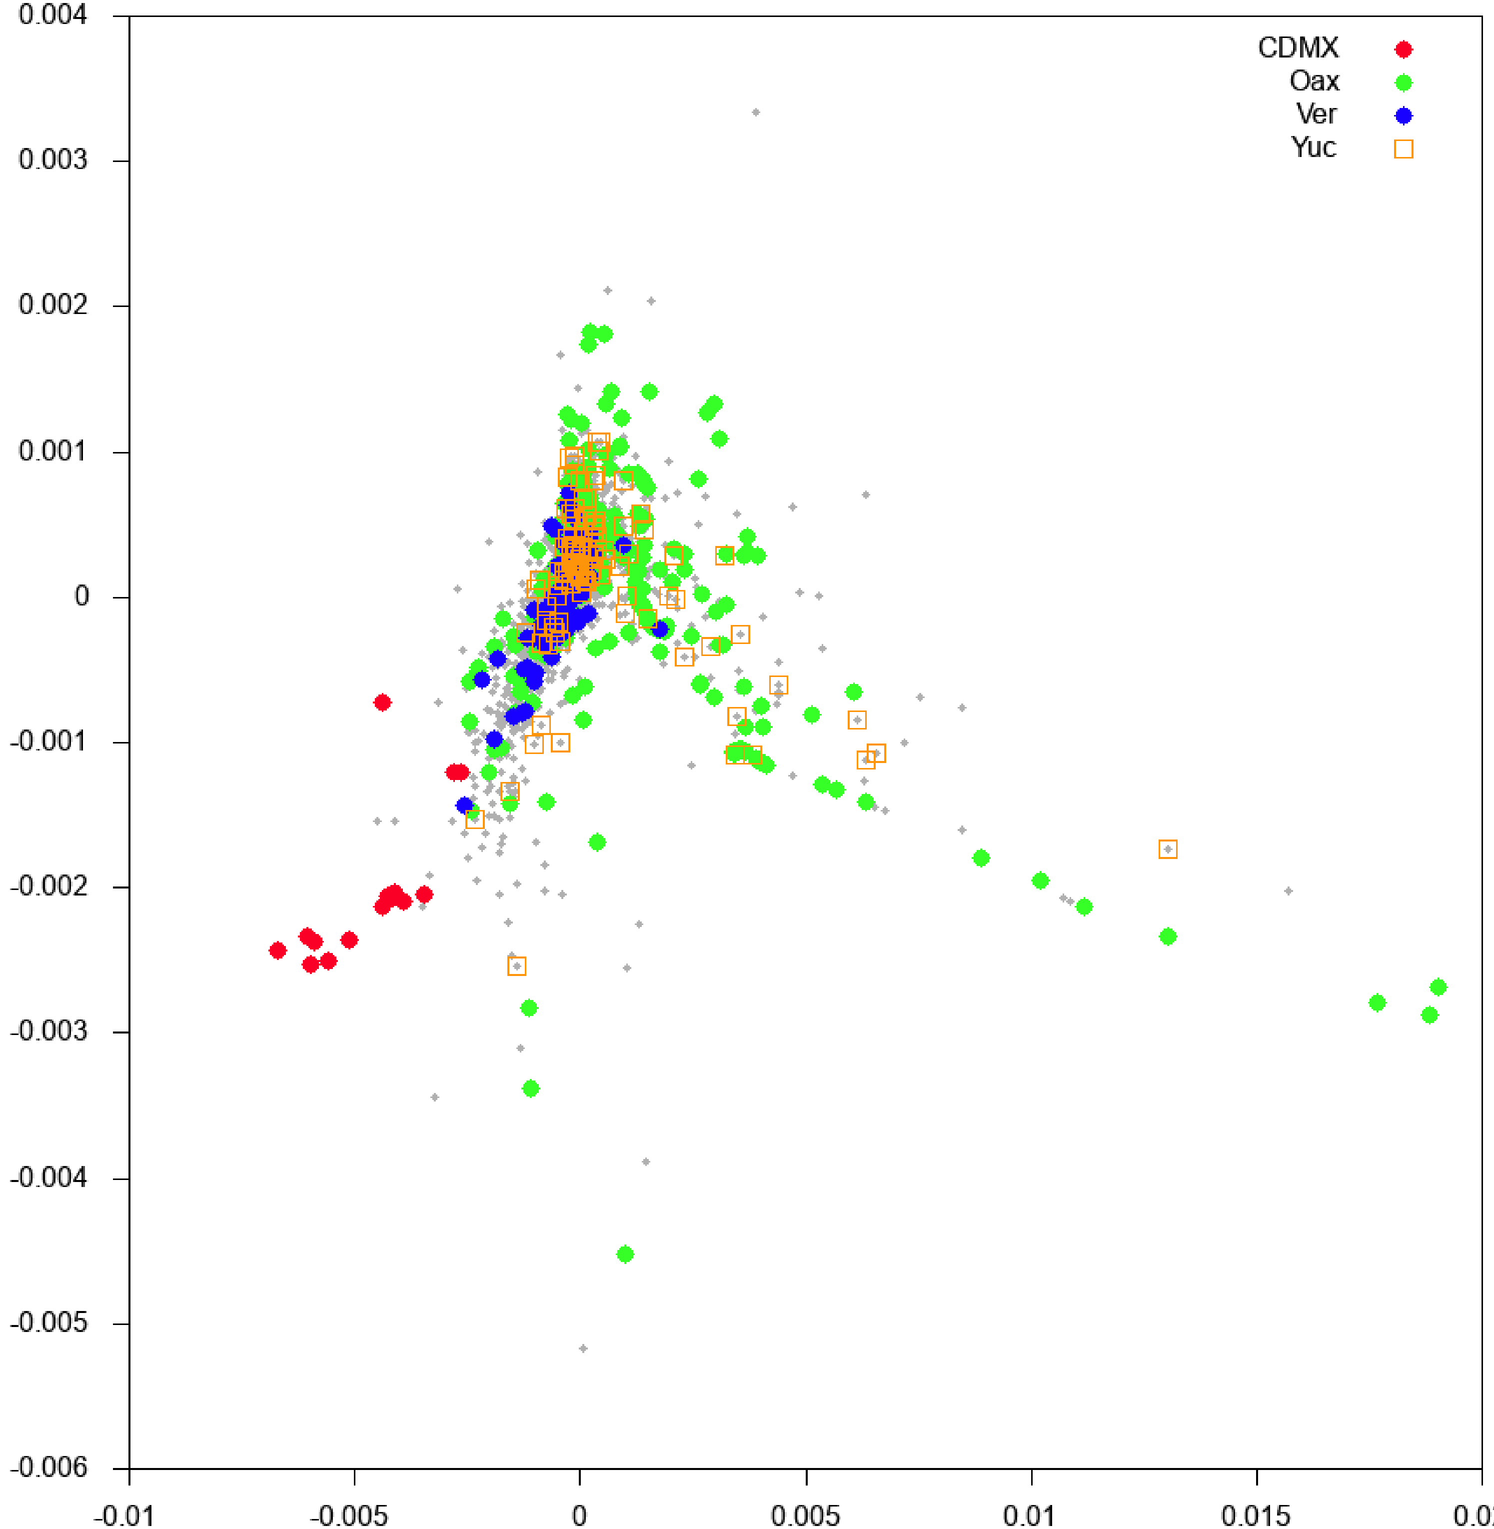
CDMX
Oax
Ver
Yuc
0.004
0.003
0.002
0.001
0
-0.001
-0.002
-0.003
-0.004
-0.005
-0.006
-0.01
-0.005
0
0.005
0.01
0.015
0.02

Isomap

Espacios multidimensionales

The Strange Geometry of High-Dimensional Spaces (II)

The volume of a high-dimensional ball is concentrated in its crust!

Let us write $B_p(0,r)$ for the p-dimensional ball centered at 0 with radius $r > 0$, and $C_p(r)$ for the "crust" obtained by removing from $B_p(0,r)$ the sub-ball $B_p(0,0.99r)$. In other words, the "crust" gathers the points in $B_p(0,r)$, which are at a distance less than $0.01r$ from its surface.

In Figure 1.5, we plot as a function of p the ratio of the volume of $C_p(r)$ to the volume of $B_p(0,r)$

$$\frac{\text{volume}(C_p(r))}{\text{volume}(B_p(0,r))} = 1 - 0.99^p,$$

which goes exponentially fast to 1.

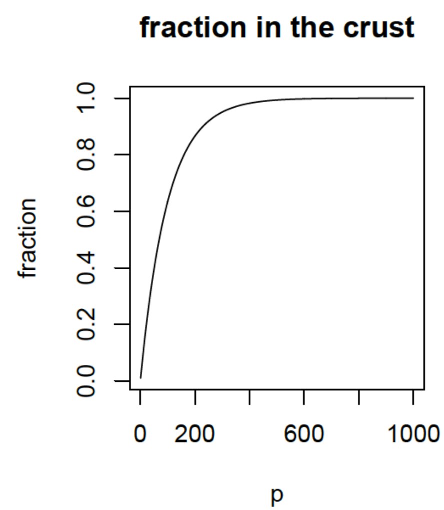

Figure 1.5

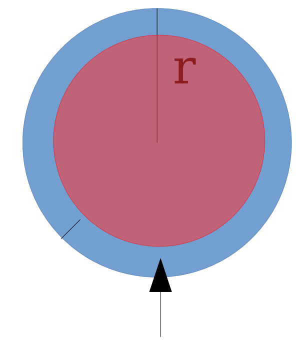

CORTEZA

(Giraud, 2015)

D = 2

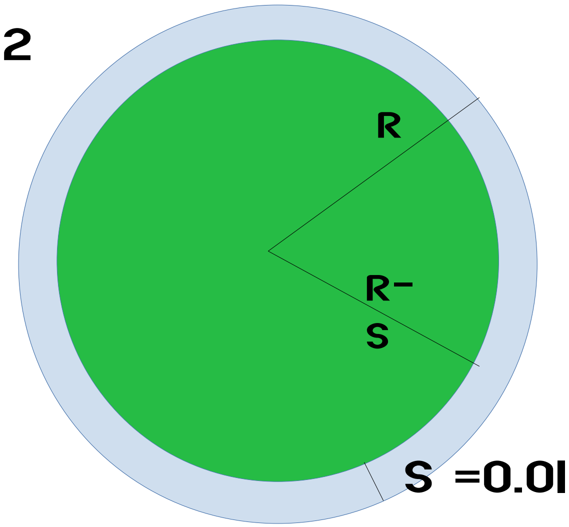

A( ) = π R² − π (R−S)²

A( ) = π (R−S)²

R = 1

$$\frac{A(\ )}{A(\ ) + A(\ )}$$

= 0.06251/(3.0789+0.06251)
= 0.01989

D = 3

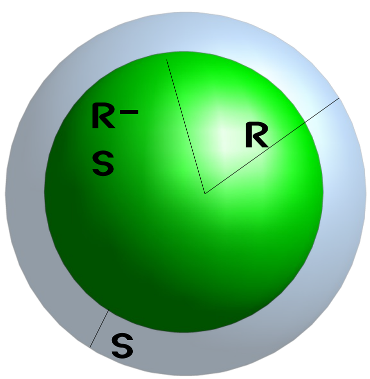

$$C = \frac{V(\ )}{V(\ )+V(\ )}$$

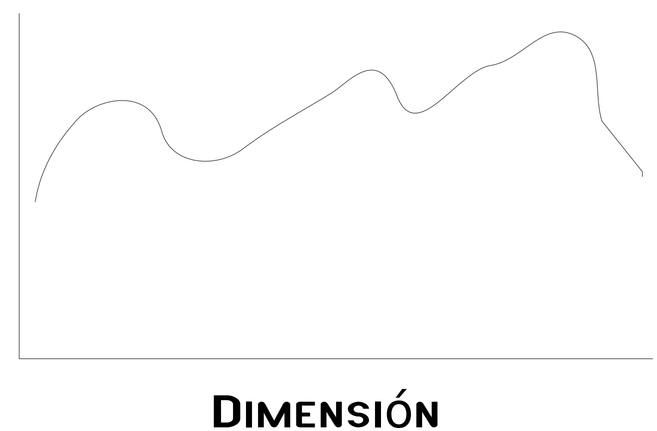

Graficar C en función de la dimensión d. d = (2, 3, 4, 5, 10, 20, 30, 40, 50, 100
200, 300, 400, 500)

¿Cuál es la distancia esperada entre un punto y los demás?

$$\text{Dist Esperada}_i = (1/N)\sum \text{dist}(i,j)$$

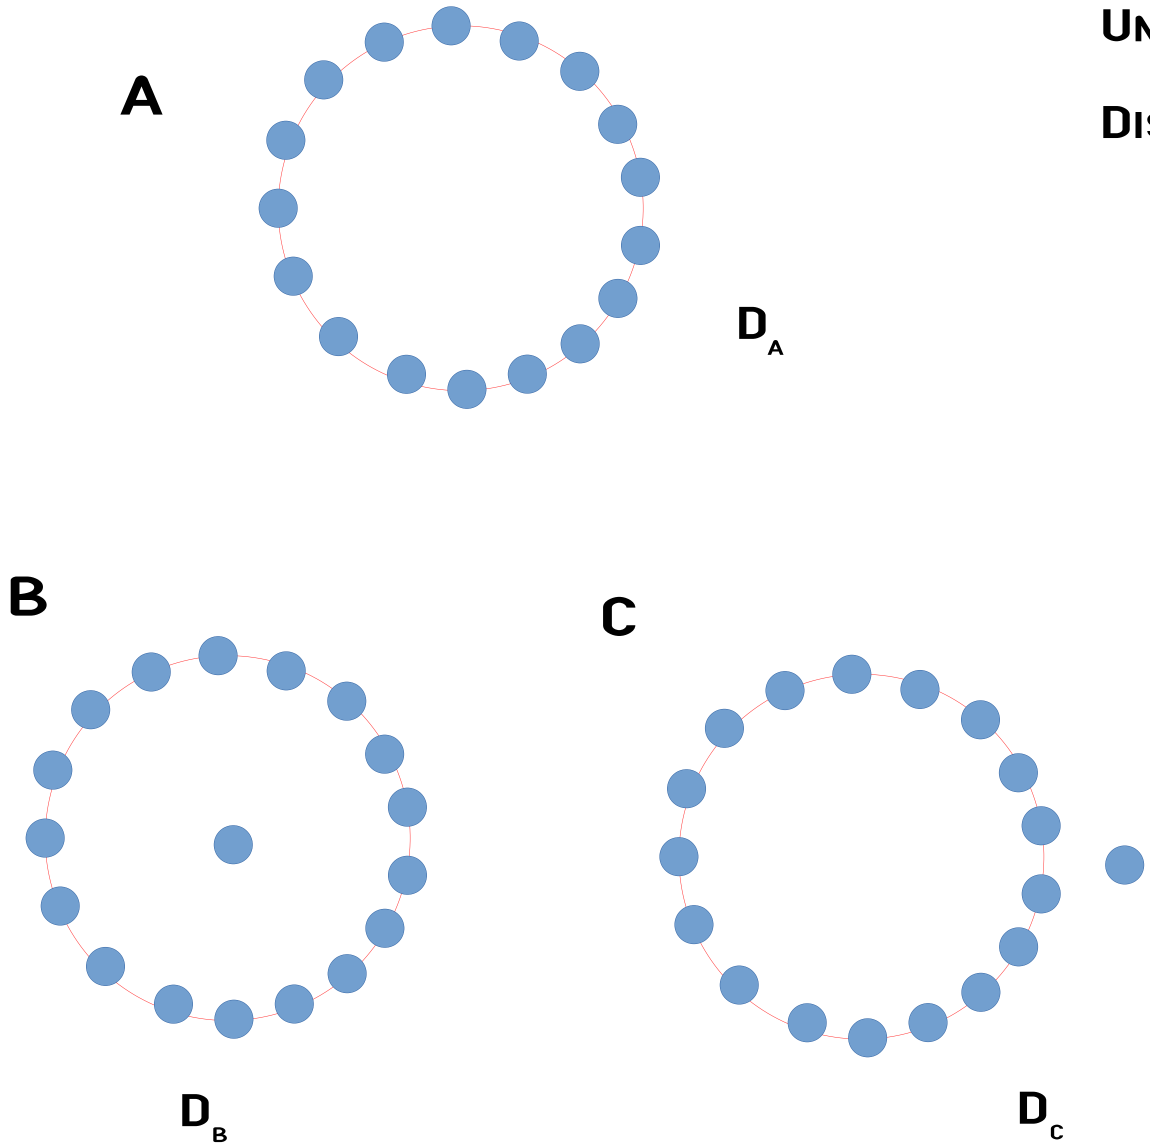

¿Cuál de las distancias D_i es mayor?

Distancias

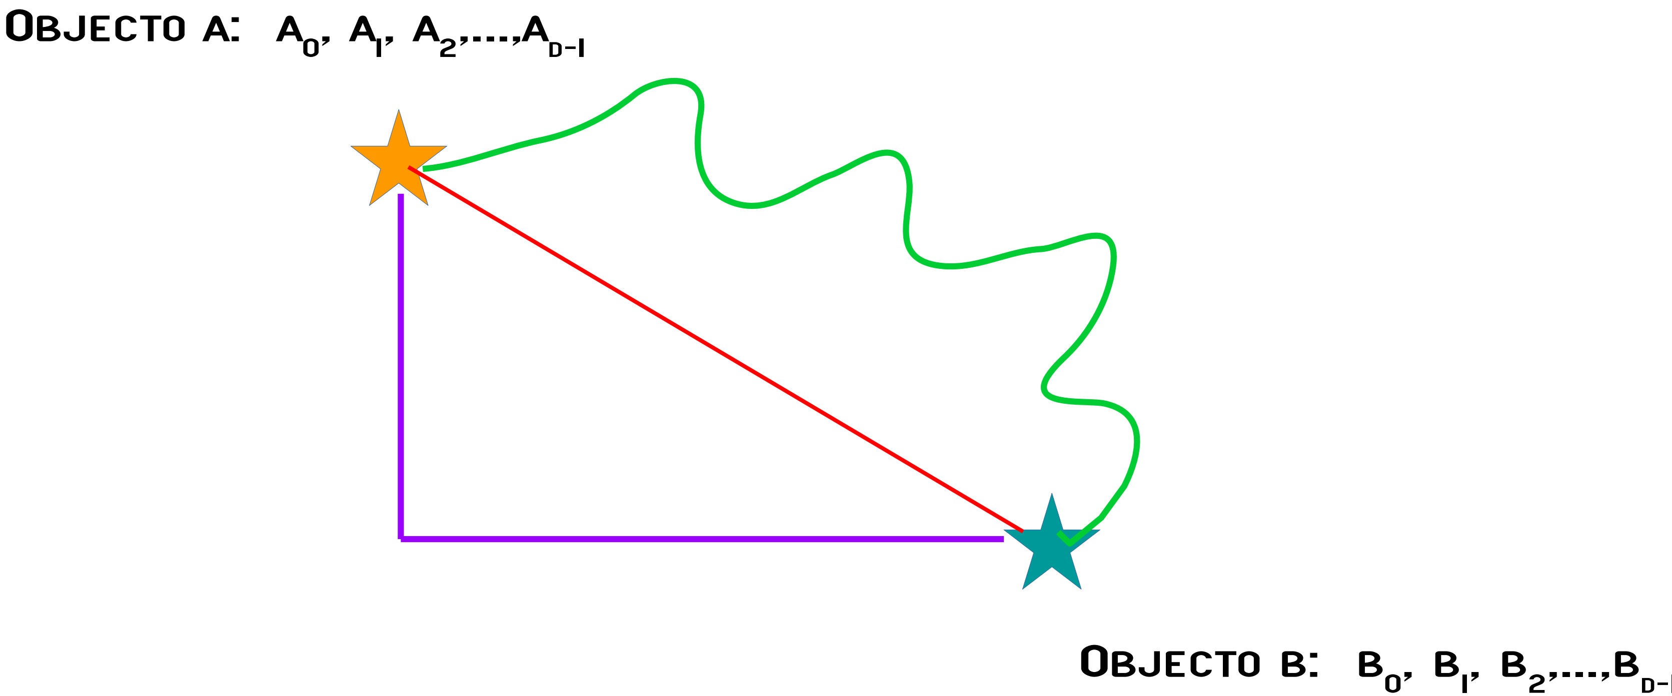

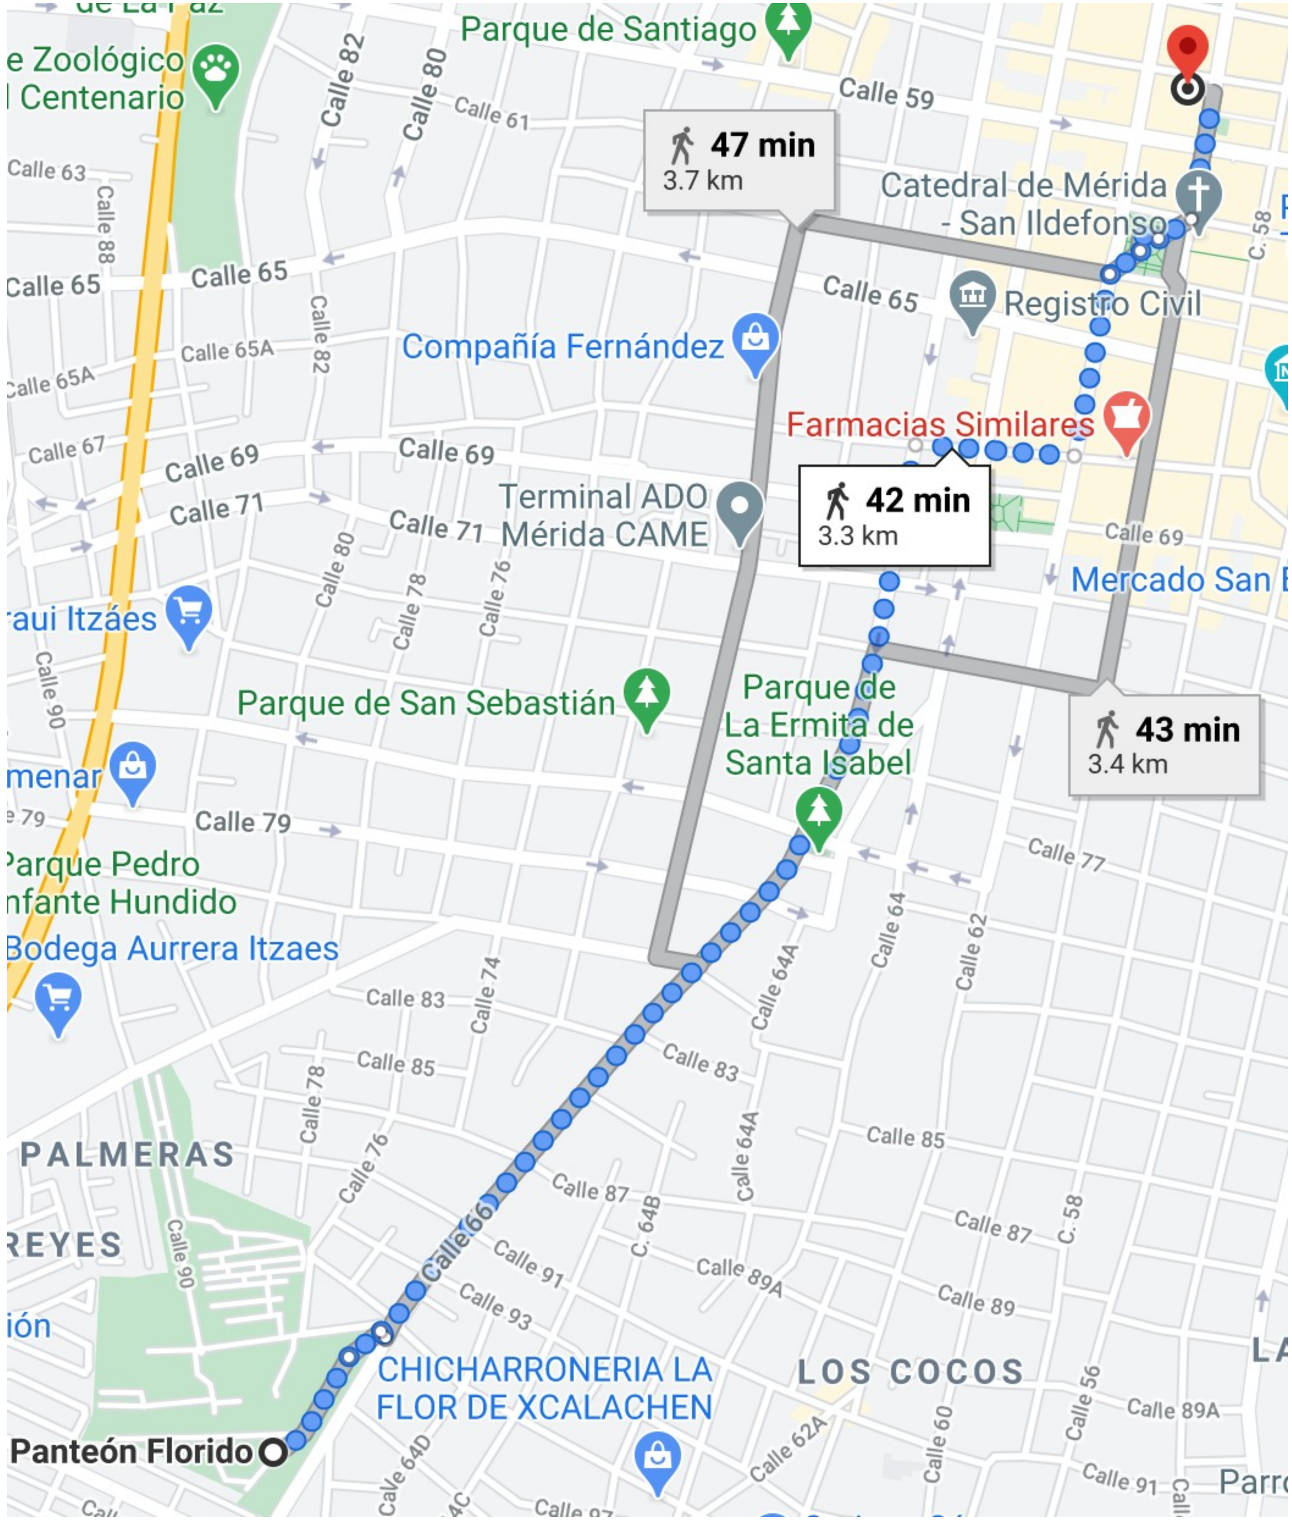
Parque de Santiago
Zoológico
Centenario
Calle 59
Calle 61
Calle 63
Calle 82
Calle 80
Calle 88
47 min
3.7 km
Catedral de Mérida - San Ildefonso
Calle 65
Calle 65A
Compañía Fernández
Registro Civil
Calle 67
Calle 69
Calle 71
Farmacias Similares
Terminal ADO Mérida CAME
42 min
3.3 km
Calle 78
Calle 76
Mercado San
Parque de San Sebastián
Parque de La Ermita de Santa Isabel
43 min
3.4 km
Calle 90
Calle 79
Calle 77
Parque Pedro
nfante Hundido
Bodega Aurrera Itzaes
Calle 83
Calle 74
Calle 64A
Calle 64
Calle 62
Calle 85
PALMERAS
Calle 87
Calle 66
Calle 91
Calle 89A
Calle 93
C. 64B
C. 58
REYES
CHICHARRONERIA LA FLOR DE XCALACHEN
LOS COCOS
Calle 56
Calle 89
Panteón Florido
Calle 64D
Calle 62A
Calle 60
Calle 91

¿Cuál es la distancia entre el conjunto A y el conjunto B?

Euclides
(siglos 3 y 4 AC)

Claude Shannon
(1916, 2001)

Herrmann Minkowski
(1864, 1909)

Una función compara objetos.

Distancia

1. $d(X,Y) \geq 0$ para cualesquiera dos puntos X,Y.
Si $X = Y$, $d(X,X) = 0$.

2. $d(X,Y) = D(Y,X)$
(simetría).

3. $d(x,z) \leq d(x,y) + d(y,z)$.
(La distancia entre dos puntos es la *mínima*).

Espacio métrico: existencia de distancia y de un conjunto de Objetos (puntos)

Norma

1

$$= \sum_{i=1}^{n} |x_i - y_i|$$

2

$$= \left(\sum_{i=1}^{n} |x_i - y_i|^2 \right)^{1/2}$$

P

$$= \left(\sum_{i=1}^{n} |x_i - y_i|^p \right)^{1/p}$$

INFINITA

$$= \lim_{p \to \infty} \left(\sum_{i=1}^{n} |x_i - y_i|^p \right)^{1/p}$$

$$= \max \left(|x_1 - y_1|, |x_2 - y_2|, \ldots, |x_n - y_n| \right).$$

¿Cuál es la distancia esperada entre Un punto y los demás?

$DE_i = (1/N)\sum dist(i,j)$

A

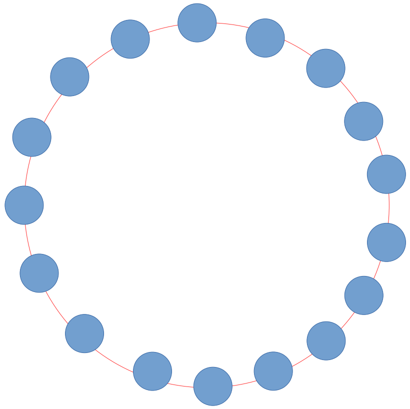

B

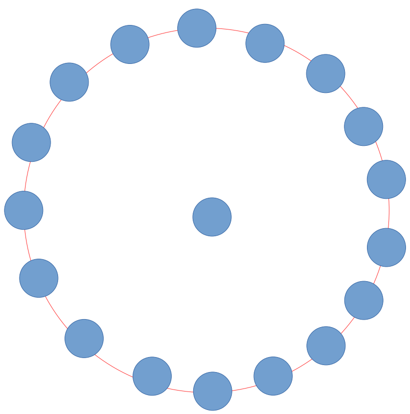

C

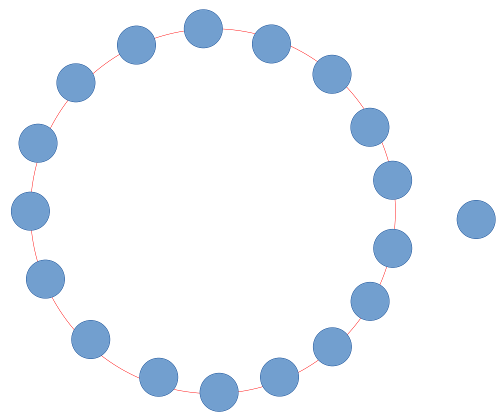

D